

Ramanalyze

Application d'analyse de spectres Raman

Documentation technique et guide utilisateur complet

Alexandre Souchaud

CitizenSers

Mars 2026

Résumé

Ramanalyze est une application de bureau développée avec PySide6 (Qt), pandas, NumPy, Plotly et scikit-learn. Elle permet d'assembler, de visualiser et d'analyser des spectres de spectroscopie Raman et SERS à partir de fichiers `.txt` bruts et de métadonnées au format Excel ou CSV.

Ce document constitue la documentation complète du logiciel : guide d'utilisation pas à pas, description de l'architecture logicielle, et introduction mathématique détaillée à l'Analyse en Composantes Principales (PCA) telle qu'elle est implémentée dans l'onglet *Exploration*. La section PCA est rédigée de façon pédagogique, avec des exemples numériques concrets, pour permettre à tout utilisateur de comprendre en profondeur ce que les composantes principales signifient physiquement et chimiquement.

Table des matières

1	Aperçu général	4
2	Fonctionnalités principales	4
3	Structure du dépôt	5
4	Installation	5
4.1	Prérequis	5
4.2	Environnement virtuel et dépendances	5
4.3	Lancement	6
5	Guide d'utilisation (pas à pas)	6
5.1	Onglet Fichiers	6
5.2	Onglet Métadonnées	6

5.2.1	Saisie des volumes	6
5.2.2	Correspondance spectres $\leftrightarrow$ tubes	7
5.2.3	Assemblage	7
5.2.4	Feuille de protocole de paillasse	7
5.3	Onglet Spectres	8
5.4	Onglet Analyse	9
5.5	Onglet Exploration (PCA)	9
5.5.1	Sous-onglets disponibles	9
5.5.2	Paramètres	9
5.5.3	Workflow typique	10
6	Comprendre la PCA en spectroscopie Raman	10
6.1	Motivation : pourquoi la PCA ?	10
6.2	Calcul pas à pas : de la matrice de spectres aux composantes	11
6.2.1	Étape 1 — Construction de la matrice de données	11
6.2.2	Étape 2 — Centrage de la matrice	11
6.2.3	Étape 3 — Matrice de covariance	12
6.2.4	Étape 4 — Décomposition en valeurs propres	12
6.2.5	Étape 5 — Calcul des scores	13
6.3	Interprétation géométrique	14
6.4	Ce que signifient PC1, PC2, PC3	15
6.4.1	PC1 : la plus grande source de variabilité	15
6.4.2	PC2 : la deuxième source de variabilité	15
6.4.3	PC3 et suivantes	15
6.5	Interpréter un loading en détail	16
6.6	Interpréter un score en détail	16
6.7	Graphe Scores PC1 <i>vs</i> PC2 : la clé de l'interprétation	17
6.8	Reconstruction à partir de N composantes	17
6.9	Variance expliquée et scree plot	18
6.10	PCA corrélée <i>vs</i> PCA libre	19
6.10.1	PCA corrélée	19
6.10.2	PCA libre	19
6.11	Résumé pratique	20
7	Génération de volumes gaussiens	20
7.1	Architecture d'un tube expérimental	20
7.2	Paramètres du dialogue	21
7.2.1	Paramètres principaux	21
7.2.2	Solutions fixes (C, D, E, F)	22
7.2.3	Contraintes de pipetage	22
7.3	Calcul du volume d'équivalence chimique	22
7.4	Génération des volumes par quantiles gaussiens	23
7.4.1	Nombre de tubes libres	23
7.4.2	Quantiles de la loi normale	23

7.4.3	Déformation pour concentrer les points autour de V_{eq}	23
7.4.4	Facteur d'échelle σ_V et bornes physiques	24
7.4.5	Conversion en volumes finaux	24
7.5	Calcul des concentrations finales dans les tubes	25
7.6	Mode compte-goutte	25
7.7	Dialogue « Quantités de matière »	26
7.8	Exemple complet numérique	26
8	Formats de fichiers attendus	27
8.1	Fichiers spectres <code>.txt</code>	27
8.2	Fichier de métadonnées	28
9	Détails techniques (modules)	28
9.1	<code>data_processing.py</code>	28
9.2	<code>metadata_model.py</code>	29
9.3	<code>metadata_creator.py</code>	30
9.4	<code>spectra_plot.py</code>	30
9.5	<code>analysis_tab.py</code>	30
9.6	<code>peak_selector.py</code>	31
10	Export et sauvegardes	31
11	Bonnes pratiques	31
12	Dépannage (FAQ)	32
13	Crédits et licence	33

1 Aperçu général

Ramanalyze guide l'utilisateur à travers les étapes suivantes :

1. **Sélection** des fichiers spectres `.txt`.
2. **Association** avec un fichier de métadonnées (Excel ou CSV).
3. **Assemblage** et correction de ligne de base (*baseline*) par l'algorithme *modpoly* de la bibliothèque `pybaselines`.
4. **Visualisation** interactive des spectres corrigés (Plotly).
5. **Analyse** des pics : intensités maximales locales et ratios entre pics.
6. **Exploration multivariée** par Analyse en Composantes Principales (PCA corrélée et PCA libre).
7. **Export** des résultats en Excel ou CSV.

2 Fonctionnalités principales

- Sélecteur de fichiers `.txt` avec navigation arborescente, ajout/retrait, liste des éléments sélectionnés.
- Lecture de métadonnées en **Excel** (`.xlsx/.xls`) et **CSV** (séparateur détecté automatiquement parmi `,`, `;`, tabulation).
- Correction de ligne de base (algorithme *modpoly*, ordre 5 par défaut) via `pybaselines`.
- Assemblage des données (spectres + métadonnées) avec prévisualisation immédiate.
- Sauvegarde du fichier combiné au choix en CSV ou Excel.
- Tracé interactif Plotly : zoom, panoramique, légende cliquable, export PNG.
- Analyse des pics : intensité maximale dans une fenêtre $[\nu_0 \pm \Delta\nu]$, ratios automatiques pour toutes les paires de pics, graphique interactif des ratios en fonction d'une variable de métadonnées.
- Export Excel des résultats (feuilles `intensites` et `ratios`).
- PCA corrélée sur les intensités aux pics sélectionnés.
- PCA libre sur les spectres complets (matrice normalisée), avec sous-onglets *Scores*, *Loadings*, *Reconstruction*.
- Scatter matrix (matrice de corrélation entre les pics).
- Génération de volumes de titrant selon une distribution gaussienne (outil *Gaus-*

sianVolumesDialog).

3 Structure du dépôt

```
spectroscopie_raman/
|-- main.py          # Point d'entree Qt : fenetre
    principale, onglets
|-- file_picker.py   # Onglet Fichiers : navigation,
    selection .txt
|-- metadata_creator.py # Onglet Metadonnees : UI Qt (volumes,
    correspondance)
|-- metadata_model.py # Couche donnees pure (sans Qt) :
    calculs, fusion
|-- spectra_plot.py   # Onglet Spectres : trace Plotly
    interactif
|-- analysis_tab.py   # Onglet Analyse : pics, ratios, export
    Excel
|-- peak_selector.py  # Onglet Exploration : PCA correlee +
    PCA libre
|-- data_processing.py # Chargement .txt, baseline, assemblage
```

Le fichier `metadata_model.py` est une **couche données pure** : il ne contient aucun import Qt et peut être importé, testé et utilisé indépendamment de l'interface graphique.

4 Installation

4.1 Prérequis

- Python 3.9 ou supérieur.
- Système d'exploitation : macOS, Linux ou Windows.

4.2 Environnement virtuel et dépendances

```
# Creer un environnement virtuel (recommande)
python -m venv .venv
source .venv/bin/activate          # macOS / Linux
# .venv\Scripts\activate           # Windows (PowerShell ou CMD)

# Installer les dependances
pip install PySide6 pandas numpy plotly pybaselines openpyxl
    scikit-learn scipy
```

Remarque

`openpyxl` est nécessaire pour lire et écrire les fichiers Excel. `PySide6` peut nécessiter des composants Qt WebEngine supplémentaires selon le système d'exploitation.

4.3 Lancement

```
python main.py
```

Une fenêtre **Ramanalyze** s'ouvre avec les onglets : *Fichiers*, *Métadonnées*, *Spectres*, *Analyse*, *Exploration*.

5 Guide d'utilisation (pas à pas)

5.1 Onglet Fichiers

1. Naviguez dans l'arborescence de fichiers (double-clic pour entrer dans un dossier).
2. Sélectionnez un ou plusieurs **fichiers .txt** de spectroscopie Raman.
3. Cliquez **Ajouter la sélection** : les fichiers sont placés dans la liste de droite.
4. Utilisez **Retirer** pour enlever un fichier individuel, ou **Vider la liste** pour recommencer.
5. Le compteur en bas indique le nombre de fichiers prêts pour l'analyse.

Remarque

Seuls les fichiers `.txt` sont listés ; les dossiers restent navigables mais n'apparaissent pas dans la sélection finale.

5.2 Onglet Métadonnées

5.2.1 Saisie des volumes

Remplissez le **tableau des volumes** (réactifs $\times$ tubes) : chaque ligne est un réactif (Solution A, B, C...), chaque colonne est un tube expérimental. Les valeurs sont en μL .

Pour générer automatiquement des volumes de titrant distribués autour de l'équivalence chimique, utilisez le bouton **Générer volumes (gaussien)**. Cf. section 7 pour le détail mathématique de cet outil.

5.2.2 Correspondance spectres ↔ tubes

Le tableau de correspondance associe chaque fichier spectre à un tube expérimental. Il peut être rempli manuellement ou généré automatiquement.

5.2.3 Assemblage

1. Cliquez **Assembler** :
 - lecture de chaque fichier `.txt`,
 - détection et suppression de l'en-tête (`Pixel;`),
 - conversion numérique, tri sur le Raman Shift,
 - correction de ligne de base (modpoly, ordre 5),
 - fusion avec les métadonnées sur la clé `Spectrum name`.
2. Vérifiez le message de succès (nombre de lignes et colonnes du fichier combiné).
3. Cliquez **Enregistrer** pour sauvegarder en CSV ou Excel.

Remarque

Le dernier chemin d'enregistrement est mémorisé pour accélérer les sauvegardes suivantes.

5.2.4 Feuille de protocole de paillasse

Le bouton **Feuille de protocole...** (onglet *Métadonnées*) ouvre un dialogue interactif destiné à **tracer les opérations de pipetage** sur la paillasse. Il affiche le tableau `df_comp` sous forme d'une grille où chaque ligne est un réactif et chaque colonne un tube expérimental.

Structure du tableau. Pour chaque tube, trois sous-colonnes sont disponibles :

- **Volume (µL)** — lecture seule ; rappelle la quantité à pipeter.
- **Coordinateur** ☐ — case validée par le coordinateur.
- **Opérateur** ☐ — case validée par l'opérateur.

Une colonne **Vérification solution** permet en outre de confirmer l'identité du flacon avant tout pipetage.

Mode guidé. En mode guidé, seule la cellule de l'étape courante est active ; toutes les autres sont grisées et désactivées. La séquence automatique suit l'ordre :

1. Vérification de la solution du réactif courant.

2. Tube 1 : confirmation du volume + case Coordinateur + case Opérateur.
3. Tube 2, Tube 3, ... jusqu'au dernier tube.
4. Passage au réactif suivant (Vérif → Tube 1 → Tube 2 → ...).

Un libellé de statut vert indique l'étape en cours : → **Vérifier la solution** : Solution A ou → **Solution A** · Tube 1.

Workflow coordinateur / opérateur. Le coordinateur coche sa case en premier (tube préparé), puis l'opérateur valide après vérification indépendante. Les boutons **Tout cocher — Coord.** et **Tout cocher — Opér.** permettent de valider toutes les cases d'un rôle en un clic ; **Tout décocher** remet tout à zéro.

Export : fichier unifié (4 feuilles). Le bouton **Exporter Excel...** génère un fichier `.xlsx` contenant les quatre feuilles suivantes :

- **Protocole** — feuille visuelle mise en forme (en-têtes colorés, texte pivoté, symboles ✓/□).
- **Volumes** — données brutes de `df_comp`.
- **Correspondance** — données brutes de `df_map`.
- **EtatProtocole** — état de chaque case (`type`, `r_idx`, `t_idx`, `checked`).

Persistance et rechargement.

- Fermeture du dialogue : l'état des cases est conservé en mémoire.
- **Enregistrer les métadonnées...** : la feuille `EtatProtocole` est incluse automatiquement dans le fichier sauvegardé.
- **Charger des métadonnées...** : si le fichier contient une feuille `EtatProtocole`, toutes les cases reprennent exactement l'état sauvegardé.

Remarque

Récapitulatif du flux de travail en paillasse :

1. Ouvrir **Feuille de protocole...**
2. Suivre le mode guidé : Vérif → Coord → Opér, tube par tube.
3. Cliquer **Exporter Excel...** pour archiver.
4. Recharger le fichier à tout moment via **Charger des métadonnées...** pour reprendre où vous en étiez.

5.3 Onglet Spectres

- Charge automatiquement le fichier combiné produit à l'étape précédente.

- Filtre sur les fichiers sélectionnés dans l'onglet *Fichiers* (colonne **file**).
- La légende utilise **Sample description** si disponible, sinon le nom de fichier.
- Cliquez **Tracer avec baseline** pour générer la figure Plotly interactive (zoom, pan, export PNG).

5.4 Onglet Analyse

1. Rechargez le fichier combiné si nécessaire.
2. Choisissez un **jeu de pics** prédéfini :
 - **532 nm** : 1231, 1327, 1342, 1358, 1450 cm^{-1} .
 - **785 nm** : 412, 444, 471, 547, 1561 cm^{-1} .
3. Réglez la **tolérance** $\Delta\nu$ (défaut : 2,00 cm^{-1}).
4. Cliquez **Analyser les pics** :
 - recherche de l'intensité maximale dans $[\nu_0 - \Delta\nu, \nu_0 + \Delta\nu]$ pour chaque spectre et chaque pic,
 - calcul de tous les ratios I_i/I_j pour chaque paire de pics (i, j) ,
 - jointure avec les métadonnées (concentration, tube...),
 - affichage d'un tableau triable et d'un graphique interactif des ratios en fonction de **n(EGTA)** (mol).
5. **Exporter résultats (Excel)**... pour sauvegarder :
 - feuille **intensities** : intensité maximale par pic et par spectre,
 - feuille **ratios** : tous les ratios en format long.

5.5 Onglet Exploration (PCA)

L'onglet **Exploration** regroupe la sélection de pics et deux modes de PCA, accessibles via des sous-onglets.

5.5.1 Sous-onglets disponibles

5.5.2 Paramètres

- **Composantes PCA corrélée** : nombre de composantes principales pour la PCA sur les intensités aux pics.
- **Composantes PCA libre** : nombre de composantes pour la PCA sur les spectres complets (2 à 15).

TABLE 1 – Sous-onglets de l’onglet Exploration.

Sous-onglet	Description
Spectres normalisés	Superposition des spectres après normalisation par leur norme vectorielle
Spectres superposés	Superposition brute (sans normalisation)
PCA corrélée	PCA calculée sur la matrice des intensités aux pics sélectionnés uniquement
PCA — Scores	Position de chaque spectre dans l’espace défini par les composantes de la PCA libre
PCA — Loadings	Poids de chaque nombre d’onde pour chaque composante (affiché comme un spectre)
PCA — Reconstruction	Reconstruction d’un spectre à partir de N composantes seulement
Scatter matrix	Matrice de nuages de points entre toutes les paires de pics (corrélations visuelles)

— **Colorier par** : variable de métadonnées utilisée pour colorer les points dans les graphiques de scores, spectres...

5.5.3 Workflow typique

1. Rechargez les données.
2. Définissez vos pics cibles et la tolérance.
3. Lancez l’analyse.
4. Consultez le sous-onglet **PCA — Scores** (colorié par concentration) : les spectres se séparent-ils selon votre variable d’intérêt ?
5. Consultez **PCA — Loadings** : à quels nombres d’onde les axes sont-ils sensibles ?
6. Utilisez **PCA — Reconstruction** avec $N = 1$, $N = 2$, $N = 3 \dots$ pour visualiser ce que chaque composante capture réellement.

6 Comprendre la PCA en spectroscopie Raman

6.1 Motivation : pourquoi la PCA ?

Un spectre Raman est un vecteur de $p \approx 1\,000$ points, chaque composante étant l’intensité à un nombre d’onde donné. Si l’on dispose de $n = 15$ spectres, chaque spectre est un **point dans un espace à $p = 1\,000$ dimensions**.

Ce que l’on cherche à comprendre expérimentalement :

— Les spectres se ressemblent-ils selon la concentration en titrant ?

- Y a-t-il des groupes distincts d'échantillons ?
- Quelles bandes Raman varient le plus entre les tubes ?

Répondre à ces questions directement dans un espace à 1 000 dimensions est impossible. La **PCA** (Analyse en Composantes Principales) résout ce problème en cherchant les quelques **directions** dans cet espace qui capturent le plus de variabilité entre spectres, puis en projetant tous les spectres sur ces directions pour obtenir une représentation en 2D ou 3D facilement visualisable.

À retenir

La PCA ne « perd » pas l'information arbitrairement : elle choisit les directions qui **maximisent la variance conservée**. Les premières composantes capturent donc l'essentiel de la variabilité réelle.

6.2 Calcul pas à pas : de la matrice de spectres aux composantes

6.2.1 Étape 1 — Construction de la matrice de données

On empile les n spectres en lignes pour former une matrice $\mathbf{X}$ de taille $n \times p$:

$$\mathbf{X} = \begin{pmatrix} x_{1,1} & x_{1,2} & \cdots & x_{1,p} \\ x_{2,1} & x_{2,2} & \cdots & x_{2,p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n,1} & x_{n,2} & \cdots & x_{n,p} \end{pmatrix}$$

où $x_{i,j}$ est l'intensité du spectre i au nombre d'onde ν_j (après correction de baseline).

Exemple concret

Avec $n = 15$ spectres et $p = 1\,000$ nombres d'onde :

	ν_1	ν_2	$\cdots$	ν_{1000}
Spectre 1	120	45	$\cdots$	8
Spectre 2	118	47	$\cdots$	9
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$
Spectre 15	130	41	$\cdots$	7

6.2.2 Étape 2 — Centrage de la matrice

Avant tout calcul, on **centre** la matrice : pour chaque nombre d'onde j , on soustrait la moyenne des n spectres à cette fréquence.

$$\tilde{x}_{i,j} = x_{i,j} - \bar{x}_j \quad \text{où} \quad \bar{x}_j = \frac{1}{n} \sum_{k=1}^n x_{k,j}$$

Après centrage, chaque colonne de $\tilde{\mathbf{X}}$ a une **moyenne nulle**. On travaille désormais sur les **écarts** par rapport au spectre moyen $\bar{\mathbf{x}} = (\bar{x}_1, \dots, \bar{x}_p)$: c'est ce qui varie d'un spectre à l'autre qui est informatif, pas la valeur absolue de l'intensité.

Remarque

Le centrage est une étape **obligatoire** en PCA. Sans centrage, la première composante principale serait simplement la direction du vecteur moyen $\bar{\mathbf{x}}$ (la valeur absolue la plus grande), ce qui n'a pas de sens physique.

6.2.3 Étape 3 — Matrice de covariance

On calcule la **matrice de covariance** $\mathbf{C}$ de taille $p \times p$:

$$\mathbf{C} = \frac{1}{n-1} \tilde{\mathbf{X}}^\top \tilde{\mathbf{X}}$$

Chaque élément $C_{i,j}$ est la **covariance** entre les intensités aux nombres d'onde ν_i et ν_j :

$$C_{i,j} = \frac{1}{n-1} \sum_{k=1}^n \tilde{x}_{k,i} \tilde{x}_{k,j}$$

Interprétation physique :

- $C_{i,j} > 0$: quand l'intensité à ν_i est élevée (au-dessus de sa moyenne), celle à ν_j l'est aussi. Les deux bandes Raman **varient de concert** — elles sont probablement liées au même phénomène chimique.
- $C_{i,j} < 0$: les deux bandes varient en sens opposé.
- $C_{i,j} \approx 0$: les bandes sont indépendantes.
- $C_{i,i} = \text{Var}(\nu_i)$: variance de l'intensité à ν_i sur l'ensemble des spectres.

La matrice $\mathbf{C}$ encode ainsi **toutes les corrélations entre bandes Raman** dans un seul objet mathématique de taille $1\,000 \times 1\,000$.

6.2.4 Étape 4 — Décomposition en valeurs propres

On résout le **problème aux valeurs propres** de $\mathbf{C}$:

$$\mathbf{C} \mathbf{v}_k = \lambda_k \mathbf{v}_k$$

Cette équation admet p solutions (paires $(\lambda_k, \mathbf{v}_k)$) :

- $\lambda_k \geq 0$ est la **valeur propre**, proportionnelle à la variance expliquée par la k -ième composante.
- $\mathbf{v}_k \in \mathbb{R}^p$ est le **vecteur propre** associé, appelé **loading** de la composante PC_k . Il est de norme unitaire ($\|\mathbf{v}_k\| = 1$) et a exactement la même longueur que les spectres (un coefficient par nombre d'onde).

On trie les paires par valeur propre décroissante : $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$. Le plus grand λ_1 donne **PC1**, le second λ_2 donne **PC2**, etc.

La **fraction de variance expliquée** par la composante k est :

$$\text{VE}_k = \frac{\lambda_k}{\sum_{j=1}^p \lambda_j}$$

et la variance expliquée **cumulée** par les N premières composantes :

$$\text{VE}_{\text{cum}}(N) = \frac{\sum_{k=1}^N \lambda_k}{\sum_{j=1}^p \lambda_j}$$

Exemple concret

Si $\text{VE}_1 = 72\%$, $\text{VE}_2 = 15\%$, $\text{VE}_3 = 6\%$, alors les 3 premières composantes expliquent $72 + 15 + 6 = 93\%$ de toute la variabilité entre spectres. Les 997 composantes restantes partagent les 7% restants (principalement du bruit).

Pourquoi les valeurs propres de C ?

La matrice **C** est symétrique positive. Ses vecteurs propres forment une **base orthonormée** de $\mathbb{R}^p$: deux composantes principales distinctes sont toujours perpendiculaires, ce qui garantit qu'elles capturent des informations *indépendantes*. C'est une propriété fondamentale de la PCA : les composantes ne se répètent pas entre elles.

6.2.5 Étape 5 — Calcul des scores

Le **score** du spectre i sur la composante PC_k est le **produit scalaire** entre le spectre centré et le loading :

$$s_{i,k} = \tilde{\mathbf{x}}_i \cdot \mathbf{v}_k = \sum_{j=1}^p \tilde{x}_{i,j} v_{k,j}$$

Intuition : on « projette » le spectre sur la direction $\mathbf{v}_k$. Le résultat est **un seul nombre** par spectre et par composante.

La matrice des scores $\mathbf{S}$ de taille $n \times K$ (avec K composantes retenues) s'écrit :

$$\mathbf{S} = \tilde{\mathbf{X}} \cdot \mathbf{V}$$

où $\mathbf{V} = [\mathbf{v}_1 \mid \mathbf{v}_2 \mid \cdots \mid \mathbf{v}_K]$ est la matrice des loadings ($p \times K$).

Exemple concret

Avec 15 spectres et 2 composantes retenues :

	Score PC1	Score PC2
Spectre 1	−3,2	0,8
Spectre 2	−2,8	1,1
Spectre 3	−1,1	0,3
⋮	⋮	⋮
Spectre 15	+4,1	−0,5

On peut maintenant tracer ces 15 spectres dans le plan (PC1, PC2) — en 2 dimensions au lieu de 1 000.


6.3 Interprétation géométrique

Imaginons que chaque spectre soit un **point dans l'espace à p dimensions**. Les n spectres forment un **nuage de points** dans cet espace.

Ce nuage n'est pas sphérique : il est allongé dans certaines directions (là où les spectres varient beaucoup entre eux) et aplati dans d'autres (là où les spectres se ressemblent).

- **PC1** = l'axe selon lequel le nuage est le *plus allongé* (variance maximale).
- **PC2** = l'axe perpendiculaire à PC1 selon lequel le nuage est le *deuxième plus allongé*.
- **PC3** = perpendiculaire aux deux précédents, troisième variance maximale.
- ...

La PCA trouve la meilleure « orientation » pour regarder ce nuage depuis un espace de faible dimension.



Chaque point représente un spectre. Sa position sur l'axe PC1 mesure sa « ressemblance » avec le pattern du loading PC1.

6.4 Ce que signifient PC1, PC2, PC3...

6.4.1 PC1 : la plus grande source de variabilité

PC1 capture la direction dans laquelle les spectres varient **le plus**. C'est la composante qui explique la plus grande fraction de la variance totale.

Important : PC1 n'est pas nécessairement la plus chimiquement intéressante. Elle capturera simplement la plus grande source de variabilité, qu'il s'agisse :

- d'une **variation de fluorescence de fond** (ligne de base) entre spectres — artefact instrumental courant,
- d'une **variation de puissance laser** entre sessions de mesure,
- ou de l'effet chimique recherché (concentration, pH, etc.) si c'est bien lui qui domine la variabilité.

6.4.2 PC2 : la deuxième source de variabilité

Perpendiculaire à PC1 (au sens du produit scalaire, donc mathématiquement indépendante), PC2 capture la **deuxième source de variabilité** après que PC1 a « absorbé » la plus grande.

À retenir

Dans une expérience SERS de titration bien menée, si la fluorescence de fond constitue la principale source de variabilité, **PC1 capturera cet artefact** et **PC2 contiendra l'effet chimique de la concentration en titrant**. Il faut donc regarder *plusieurs* composantes, pas seulement PC1.

6.4.3 PC3 et suivantes

Capturent des effets de plus en plus mineurs. En pratique, dans les spectres Raman/-SERS :

- PC1–PC2 : les deux principaux effets (ligne de base + chimie, ou deux effets chimiques distincts).
- PC3–PC5 : effets secondaires, variations locales.

— Au-delà de PC5 : **bruit de mesure** dans la plupart des cas.

Le « coude » du graphe des valeurs propres (*scree plot*) indique généralement combien de composantes sont physiquement significatives.

6.5 Interpréter un loading en détail

Le loading $\mathbf{v}_k \in \mathbb{R}^p$ de la composante PC_k est un vecteur de p coefficients, un par nombre d'onde. On peut le **tracer en fonction du Raman Shift** exactement comme un spectre expérimental.

$$\mathbf{v}_1 = \left[\underbrace{0,02}_{\nu_1}, \underbrace{-0,01}_{\nu_2}, 0,00, \underbrace{0,15}_{\nu_4}, \dots, \underbrace{0,08}_{\nu_{1000}} \right]$$

Règle d'interprétation des coefficients du loading :

- Coefficient **grand positif** à ν_j : PC1 est très sensible à l'intensité à ν_j . Les spectres avec un *score PC1 positif* ont une intensité élevée à cette bande.
- Coefficient **proche de zéro** à ν_j : PC1 est insensible à cette bande. Elle ne contribue pas à différencier les spectres selon PC1.
- Coefficient **négatif** à ν_j : les spectres avec un *score PC1 négatif* ont une intensité élevée à ν_j , et vice-versa.

Méthode pratique :

1. Tracer le loading comme un spectre ($v_{k,j}$ en ordonnée, ν_j en abscisse).
2. Identifier les pics et les creux, exactement comme pour un spectre expérimental.
3. Associer chaque pic à un mode de vibration connu (bases de données Raman, littérature).
4. **Conclusion** : la composante PC_k est dominée par les modes de vibration correspondant aux pics du loading.

Exemple concret

Si le loading PC2 montre des pics à 1 100 et 1 340 cm^{-1} , et que ces bandes correspondent à des modes de vibration d'un ligand qui chélate le Cu^{2+} , alors **PC2 capture la réaction de complexation** entre le ligand et le Cu^{2+} — i.e., l'effet chimique de la titration.

6.6 Interpréter un score en détail

Le score $s_{i,k}$ du spectre i sur PC_k est sa « coordonnée » sur l'axe de la k -ième composante.

- Score **très positif** : ce spectre ressemble fortement au pattern décrit par le loading PC_k (intensités élevées aux nombres d'onde à coefficients positifs dans le loading, et basses là où les coefficients sont négatifs).
- Score **proche de zéro** : ce spectre est « neutre » par rapport à PC_k . Il ne se distingue pas des autres selon cet axe.
- Score **très négatif** : ce spectre est « opposé » au pattern de PC_k (intensités élevées là où le loading est négatif).

Relation entre score et loading : Le score est littéralement le **produit scalaire** entre le spectre centré et le loading. C'est une mesure de **similarité orientée** entre le spectre et la direction PC_k .

6.7 Graphe Scores PC1 vs PC2 : la clé de l'interprétation

C'est le graphe le plus important de la PCA. On représente chaque spectre par un point de coordonnées $(s_{i,1}, s_{i,2})$, et on **colorie** les points selon une variable de métadonnées (concentration, tube, opérateur...).

Questions auxquelles ce graphe répond :

1. **Les spectres se séparent-ils selon ma variable d'intérêt ?**
 - Points séparés *le long de PC1* selon la concentration $\Rightarrow$ PC1 capture l'effet chimique de la titration.
 - Points séparés *le long de PC2* selon la concentration $\Rightarrow$ l'effet chimique est la 2^e source de variance (PC1 capturerait un artefact).
 - Points *mélangés aléatoirement* $\Rightarrow$ la variabilité principale n'est pas liée à la concentration.
2. **Y a-t-il des groupes (clusters) d'échantillons ?** Des points regroupés en nuages distincts indiquent des états chimiques ou physiques différents.
3. **Y a-t-il des spectres aberrants (outliers) ?** Un point très éloigné des autres signale un spectre anormal (contamination, problème instrumental, mauvaise baseline...).

Remarque

On peut aussi tracer PC1 vs PC3, PC2 vs PC3, etc. Chaque combinaison révèle une facette différente de la variabilité.

6.8 Reconstruction à partir de N composantes

L'onglet **PCA — Reconstruction** permet de reconstituer un spectre à partir de N composantes seulement, selon la formule :

$$\hat{\mathbf{x}}_i = \bar{\mathbf{x}} + \sum_{k=1}^N s_{i,k} \mathbf{v}_k$$

où $\bar{\mathbf{x}}$ est le spectre moyen (ajouté après centrage pour revenir dans l'espace original).

Comment l'utiliser ?

- $N = 1$: on voit uniquement ce que PC1 a capturé dans ce spectre. Si PC1 capturerait la ligne de base, le spectre reconstruit ressemble à une ligne de base lisse.
- $N = 2$: on ajoute la contribution de PC2. Si PC2 capturerait l'effet de la concentration, le spectre reconstruit montre maintenant les pics chimiques en plus.
- $N = 3$: on ajoute PC3, etc.
- $N = p$ (**toutes les composantes**) : on retrouve exactement le spectre original (reconstruction parfaite).

Intérêt pratique : En comparant le spectre reconstruit avec N et $N - 1$ composantes, on voit **exactement ce qu'ajoute la N -ième composante**. C'est la méthode la plus directe pour comprendre ce que chaque composante capture physiquement.

6.9 Variance expliquée et scree plot

La **variance expliquée cumulée** est :

$$\text{VE}_{\text{cum}}(N) = \sum_{k=1}^N \text{VE}_k = \frac{\sum_{k=1}^N \lambda_k}{\sum_{j=1}^p \lambda_j}$$

On cherche généralement le plus petit N tel que $\text{VE}_{\text{cum}}(N) \geq 90\%$ (ou 95% selon les usages).

Le **scree plot** est le graphe des valeurs propres λ_k en fonction du rang k . On cherche le « coude » : le point où la courbe change nettement de pente, indiquant que les composantes suivantes capturent surtout du bruit.

Exemple concret

Composante	VE (%)	VE cumulée (%)
PC1	72,4	72,4
PC2	14,8	87,2
PC3	5,6	92,8
PC4	2,1	94,9
PC5	1,3	96,2
PC6–PC15	3,8	100,0

Le coude est entre PC3 et PC4 : 3 composantes expliquent 92,8 % de la variance, et PC4–PC15 n'apportent que 7,2 % supplémentaires. On retiendra donc 3 composantes.

6.10 PCA corrélée *vs* PCA libre

L'onglet Exploration propose deux modes de PCA :

6.10.1 PCA corrélée

La PCA est appliquée uniquement sur la **matrice des intensités aux pics sélectionnés**. Si 5 pics sont définis, la matrice est $n \times 5$.

- **Avantages** : très rapide, facile à interpréter (5 variables seulement), moins sensible au bruit hors des pics.
- **Inconvénients** : dépend fortement du choix des pics. Si un pic pertinent est oublié, l'information est perdue.

6.10.2 PCA libre

La PCA est appliquée sur la **matrice complète des spectres normalisés** ($n \times p$, avec $p \approx 1\,000$).

- **Avantages** : ne suppose aucun choix a priori de pics. L'algorithme trouve lui-même les régions spectrales les plus discriminantes (via les loadings). Idéal en mode exploratoire.
- **Inconvénients** : plus sensible au bruit large bande, les loadings sont plus difficiles à interpréter car ils impliquent 1 000 coefficients.

À retenir

Dans la **PCA libre**, les spectres sont normalisés par leur norme vectorielle avant la décomposition. Cela garantit que les différences d'intensité globale (puissance laser variable) ne dominent pas les composantes.

6.11 Résumé pratique

TABLE 2 – Résumé des éléments à analyser en PCA.

Élément	Ce que ça dit
Loading PC_k tracé comme spectre	Quelles bandes Raman portent la composante k . Les pics du loading correspondent aux modes de vibration les plus discriminants.
Score PC_k d'un spectre	À quel point ce spectre ressemble au pattern décrit par le loading de PC_k . Valeur positive = forte ressemblance, négative = opposé.
Graphe scores PC1 vs PC2, coloré par variable	La PCA sépare-t-elle les échantillons selon la chimie ? Permet de détecter des groupes, des tendances, des outliers.
Variance expliquée (ex. 72 %)	PC1 résume 72 % de toute la variabilité entre spectres. Plus c'est élevé, plus la composante est importante.
Scree plot	Graphe des valeurs propres : le coude indique combien de composantes sont significatives (au-delà = bruit).
Reconstruction avec N composantes	Permet de visualiser exactement ce que les N premières composantes ont capturé dans un spectre donné.

7 Génération de volumes gaussiens

L'outil **Générer volumes (gaussien)** (bouton dans l'onglet Métadonnées) calcule automatiquement les volumes de titrant à pipeter dans chaque tube pour réaliser une titration SERS autour de l'équivalence chimique. Cette section décrit en détail chaque paramètre, le calcul des volumes de chaque solution, et le comportement en mode compte-goutte.

7.1 Architecture d'un tube expérimental

Chaque tube contient exactement **six composants**. Deux varient d'un tube à l'autre (A et B), les quatre autres sont identiques dans tous les tubes (C, D, E, F) :

De plus, l'échantillon lui-même (Cu^{2+}) est présent en volume $V_{\text{échant}}$ identique dans tous les tubes.

TABLE 3 – Composition d'un tube expérimental.

Solution	Rôle	Description	Volume
A	Tampon	Complément pour maintenir V_{tot} constant	Variable
B	Titrant	Substance dont on fait varier la quantité	Variable
C	Indicateur	Volume fixe, identique dans tous les tubes	Fixe
D	PEG	Volume fixe, identique dans tous les tubes	Fixe
E	Nanoparticules	Volume fixe, identique dans tous les tubes	Fixe
F	Crosslinker	Volume fixe, identique dans tous les tubes	Fixe

Le volume total d'un tube j est donc :

$$V_{\text{tot},j} = V_{\text{échant}} + V_{A,j} + V_{B,j} + V_C + V_D + V_E + V_F$$

Comme les solutions C, D, E, F et l'échantillon ont le même volume dans tous les tubes, on définit :

$$V_{\text{fixe}} = V_{\text{échant}} + V_C + V_D + V_E + V_F$$

et le volume disponible pour A et B dans chaque tube est :

$$V_{AB} = V_{\text{tot}} - V_{\text{fixe}}$$

La contrainte fondamentale est que **tous les tubes ont le même volume total** V_{tot} , ce qui impose :

$$V_{A,j} + V_{B,j} = V_{AB} \quad \forall j$$

7.2 Paramètres du dialogue

7.2.1 Paramètres principaux

Nombre de tubes N Nombre total de tubes (2–200, défaut : 11). Inclut éventuellement le tube à 0 μL et le tube dupliqué.

C0 Cu (nM) Concentration initiale de Cu^{2+} dans l'échantillon pur, en nanomolaires. Sert à calculer la quantité de matière de Cu^{2+} par tube :

$$n_{\text{Cu}} = C_0 [\text{nM}] \times 10^{-9} \times V_{\text{échant}} [\mu\text{L}] \times 10^{-6} \quad [\text{mol}]$$

V échantillon (μL) Volume d'échantillon par tube, identique pour tous. C'est le volume qui fixe n_{Cu} (et donc V_{eq}).

C titrant (μM) Concentration du stock de titrant (Solution B), en micromolaires.

V total par tube (μL) Volume final souhaité dans chaque tube (défaut : 3 090 μL). Sert à calculer V_{AB} .

7.2.2 Solutions fixes (C, D, E, F)

Pour chaque solution fixe, on saisit :

- V_X : le volume (μL) à pipeter dans chaque tube,
- C_X^{stock} : la concentration du stock dans l'unité choisie (M, mM, μM , nM ou % en masse).

Contrainte de quantité de matière fixe. Lorsqu'on modifie V_X ou C_X^{stock} , l'application maintient la **quantité de matière** $n_X = C_X^{\text{stock}} \times V_X$ constante et recalcule l'autre grandeur automatiquement :

$$\text{si on modifie } C_X \Rightarrow V_X = \frac{n_X}{C_X} \quad \text{si on modifie } V_X \Rightarrow C_X = \frac{n_X}{V_X}$$

Cela évite de changer accidentellement la quantité de matière injectée dans les tubes lorsqu'on ajuste la concentration du stock.

Concentrations finales dans les tubes. La concentration finale de la solution X dans le tube j est calculée par dilution :

$$C_{X,j}^{\text{final}} = C_X^{\text{stock}} \times \frac{V_X}{V_{\text{tot},j}}$$

7.2.3 Contraintes de pipetage

Marge (μL) Volume minimal et maximal pour le titrant. Le générateur garantit :

$$V_{\min} = \Delta V_{\text{marge}} \quad V_{\max} = V_{AB} - \Delta V_{\text{marge}}$$

Défaut : 20 μL . La marge évite les volumes trop petits ou trop grands, non pipetables avec précision.

Pas pipette (μL) Résolution minimale de la pipette. Tous les volumes générés sont arrondis à ce pas (défaut : 1 μL).

Inclure un tube à 0 μL de titrant Si coché, le premier tube contient $V_B = 0$ (contrôle sans titrant). Ce tube compte dans N : il reste $N - 1$ tubes libres (ou $N - 2$ si « dupliquer » est aussi coché).

Dupliquer le dernier volume Si coché, le dernier tube est un réplicat du tube précédant (même V_B). Ce tube est annoté « Contrôle » dans la correspondance spectres $\leftrightarrow$ tubes.

7.3 Calcul du volume d'équivalence chimique

L'équivalence chimique est atteinte lorsque la quantité de matière de titrant ajoutée égale exactement celle de l'analyte (Cu^{2+}). Puisque tous les tubes contiennent le même volume d'échantillon :

$$n_{\text{Cu}} = C_0 \times V_{\text{échant}}$$

le volume d'équivalence pour le titrant est :

$$V_{\text{eq}} = \frac{n_{\text{Cu}}}{C_{\text{titrant}}} = \frac{C_0 [\text{nM}] \times 10^{-9} \times V_{\text{échant}} [\mu\text{L}] \times 10^{-6}}{C_{\text{titrant}} [\mu\text{M}] \times 10^{-6}} \times 10^6 \quad [\mu\text{L}]$$

Exemple concret

$C_0 = 1000 \text{ nM}$, $V_{\text{échant}} = 1000 \mu\text{L}$, $C_{\text{titrant}} = 5 \mu\text{M}$:

$$n_{\text{Cu}} = 1000 \times 10^{-9} \times 1000 \times 10^{-6} = 10^{-6} \text{ mol}$$

$$V_{\text{eq}} = \frac{10^{-6}}{5 \times 10^{-6}} \times 10^6 = 200 \mu\text{L}$$

Le tube d'équivalence reçoit 200 μL de titrant.

7.4 Génération des volumes par quantiles gaussiens

7.4.1 Nombre de tubes libres

Le nombre de volumes *librement calculés* par l'algorithme (ni le tube à 0 μL ni le tube dupliqué) est :

$$N_{\text{libre}} = N - \mathbf{1}[\text{include_zero}] - \mathbf{1}[\text{duplicate_last}]$$

7.4.2 Quantiles de la loi normale

On génère N_{libre} probabilités uniformément espacées dans $]0, 1[$:

$$p_i = \frac{i - 0,5}{N_{\text{libre}}}, \quad i = 1, \dots, N_{\text{libre}}$$

puis on les transforme en positions gaussiennes normalisées via la **fonction quantile** (inverse de la CDF) de la loi normale standard :

$$z_i = \Phi^{-1}(p_i)$$

Exemples de valeurs : $p = 0,5 \Rightarrow z = 0$; $p = 0,16 \Rightarrow z \approx -1$; $p = 0,84 \Rightarrow z \approx +1$.

Cette transformation produit automatiquement **plus de points proches de $z = 0$** (correspondant à V_{eq}) et moins aux extrémités, reproduisant le comportement souhaité d'une titration réelle.

7.4.3 Déformation pour concentrer les points autour de V_{eq}

Les quantiles z_i sont déformés par une puissance $\gamma > 0$:

$$z'_i = \text{sign}(z_i) \times |z_i|^\gamma$$

- $\gamma = 1$: distribution gaussienne standard (pas de déformation).
- $\gamma > 1$: les points proches de 0 se resserrent encore davantage autour de V_{eq} .
Valeur typique : $\gamma = 1,8$.
- $\gamma < 1$: les points s'espacent au centre.

7.4.4 Facteur d'échelle σ_V et bornes physiques

Le facteur σ_V est choisi de façon à ce qu'aucun volume ne sorte de la plage autorisée $[V_{\text{min}}, V_{\text{max}}]$:

$$\sigma_V = \xi \times \min\left(\frac{V_{\text{max}} - V_{\text{eq}}}{z'_{\text{max}}}, \frac{V_{\text{eq}} - V_{\text{min}}}{z'_{\text{max}}}\right) \quad \text{avec} \quad z'_{\text{max}} = \max_i |z'_i|$$

Le paramètre $\xi \in]0, 1]$ (`span_frac`) contrôle le resserrement global : $\xi = 1$ fait atteindre les bornes, $\xi < 1$ reserre la distribution.

Pourquoi le minimum et non le maximum ? Utiliser le minimum garantit que les volumes ne dépassent ni d'un côté ni de l'autre. Si V_{eq} est proche d'une borne (par exemple $V_{\text{eq}} \ll V_{AB}/2$), le minimum contraint σ_V du côté le plus serré, évitant tout dépassement.

7.4.5 Conversion en volumes finaux

Volumes de titrant (Solution B) :

$$V_{B,i} = V_{\text{eq}} + \sigma_V \times z'_i$$

Clip dans les bornes physiques :

$$V_{B,i} \leftarrow \text{clip}(V_{B,i}, V_{\text{min}}, V_{\text{max}})$$

Quantification sur la grille de pipette :

$$V_{B,i}^* = \text{round}\left(\frac{V_{B,i}}{\Delta V_{\text{pipette}}}\right) \times \Delta V_{\text{pipette}}$$

Ajout du tube à 0 μL et du tube dupliqué (si demandés) :

- Si `include_zero` : $V_{B,0} = 0$ est inséré en premier.
- Si `duplicate_last` : $V_{B,N} = V_{B,N-1}$ est ajouté en dernier. Ce tube porte le label « Contrôle » dans la correspondance.

La série finale est triée par ordre croissant.

Volumes de tampon A (Solution A) :

$$V_{A,i} = V_{AB}^* - V_{B,i}^*$$

où $V_{AB}^* = \text{round}(V_{AB}/\Delta V_{\text{pipette}}) \times \Delta V_{\text{pipette}}$ est ajusté sur la grille pour garantir que $V_{A,i} + V_{B,i}^*$ est identique dans tous les tubes.

Volume total réel :

$$V_{\text{tot}}^{\text{réel}} = V_{\text{fixe}} + V_{AB}^*$$

Ce volume peut légèrement différer de V_{tot} demandé (à cause de l'arrondi sur la grille de pipette).

7.5 Calcul des concentrations finales dans les tubes

Pour chaque solution X (C, D, E, F, A, B, échantillon) et chaque tube j , la concentration finale dans la cuvette est :

$$C_{X,j}^{\text{final}} = C_X^{\text{stock}} \times \frac{V_{X,j}}{V_{\text{tot},j}}$$

- $V_{\text{tot},j} = V_{\text{échant}} + V_{A,j} + V_{B,j} + V_C + V_D + V_E + V_F$
- Pour les solutions B et A, $V_{X,j}$ varie d'un tube à l'autre.
- Pour les solutions C, D, E, F, $V_{X,j} = V_X$ est constant.
- $V_{\text{tot},j}$ est **identique** dans tous les tubes (grâce à la contrainte $V_{A,j} + V_{B,j} = V_{AB}^*$), donc les dilutions des solutions fixes sont les mêmes dans tous les tubes.

La première ligne du tableau de concentrations indique le volume total de chaque tube (en μL), les lignes suivantes les concentrations finales (en M) pour chaque réactif.

7.6 Mode compte-goutte

La case à cocher **Utilisation d'un compte-goutte** reconfigure automatiquement les paramètres de pipetage pour correspondre à la contrainte d'un compte-goutte (pas fixe et non ajustable) :

TABLE 4 – Modifications appliquées par le mode compte-goutte.

Paramètre	Valeur normale	Mode compte-goutte
Pas pipette ($\Delta V_{\text{pipette}}$)	1 μL (ajustable)	40 μL
Marge (V_{min})	20 μL	0 μL
Volume Solution C	30 μL	40 μL
Volume Solution F	60 μL	40 μL

Pourquoi pas = 40 µL ? Un compte-goutte standard délivre environ 40 µL par goutte. Tous les volumes doivent donc être des **multiples de 40 µL**. Le générateur arrondit chaque $V_{B,i}$ au multiple de 40 µL le plus proche.

Pourquoi marge = 0 ? Avec un compte-goutte, la valeur minimale pipetable est 0 (on peut ne pas mettre de goutte). Il n’y a pas de minimum imposé par la précision de la pipette.

Volumes C et F ajustés à 40 µL. Ces solutions sont souvent ajoutées goutte à goutte également. L’application les aligne sur le pas du compte-goutte pour que le volume fixe V_{fixe} reste aussi un multiple de 40 µL.

Liberté de modification. Après avoir coché la case, tous les champs restent éditables : l’utilisateur peut ajuster manuellement chaque valeur si son protocole diffère des valeurs par défaut du mode compte-goutte.

Remarque

En mode compte-goutte, la résolution des volumes est plus grossière (multiples de 40 µL). Le volume d’équivalence V_{eq} calculé est rarement un multiple exact de 40 µL ; le tube « d’équivalence » est donc arrondi au multiple le plus proche. Plus le nombre de tubes est grand, meilleure sera la couverture autour de V_{eq} .

7.7 Dialogue « Quantités de matière »

Le bouton **Quantités de matière...** ouvre un sous-dialogue qui affiche, pour chaque solution, la quantité de matière n en nmol :

$$n_X [\text{nmol}] = C_X^{\text{stock}} [\text{M}] \times V_X [\mu\text{L}] \times 10^3$$

L’utilisateur peut modifier directement n_X ; l’application recalcule C_X^{stock} en conséquence (avec V_X inchangé). Cette vue est utile lorsque le protocole est défini en quantités de matière plutôt qu’en concentrations.

7.8 Exemple complet numérique

Protocole : $N = 5$ tubes, $C_0 = 500$ nM, $V_{\text{échant}} = 1000$ µL, $C_{\text{titrant}} = 2$ µM, $V_{\text{tot}} = 3090$ µL, $V_C = 30$, $V_D = 750$, $V_E = 750$, $V_F = 60$ µL, marge = 20 µL, pas = 1 µL, 1 tube à 0 µL, pas de doublon.

Étape 1 — Volumes fixes :

$$V_{\text{fixe}} = 1000 + 30 + 750 + 750 + 60 = 2590 \mu\text{L}$$

$$V_{AB} = 3090 - 2590 = 500 \mu\text{L}$$

$$V_{\min} = 20 \text{ } \mu\text{L}, \quad V_{\max} = 480 \text{ } \mu\text{L}$$

Étape 2 — Volume d'équivalence :

$$n_{\text{Cu}} = 500 \times 10^{-9} \times 1000 \times 10^{-6} = 5 \times 10^{-7} \text{ mol}$$

$$V_{\text{eq}} = \frac{5 \times 10^{-7}}{2 \times 10^{-6}} \times 10^6 = 250 \text{ } \mu\text{L}$$

Étape 3 — Tubes libres :

$$N_{\text{libre}} = 5 - 1 - 0 = 4 \quad (4 \text{ tubes à calculer} + 1 \text{ tube à } 0)$$

Étape 4 — Quantiles ($\gamma = 1,8$) :

i	p_i	$z_i = \Phi^{-1}(p_i)$	$z'_i = \text{sign}(z_i) z_i ^{1.8}$	$V_{B,i} \text{ (}\mu\text{L)}$
1	0,125	-1,15	-1,44	$250 - \sigma \times 1,44$
2	0,375	-0,32	-0,12	$250 - \sigma \times 0,12$
3	0,625	+0,32	+0,12	$250 + \sigma \times 0,12$
4	0,875	+1,15	+1,44	$250 + \sigma \times 1,44$

$$z'_{\max} = 1,44, \sigma_V = \min\left(\frac{230}{1,44}, \frac{230}{1,44}\right) = 160 \text{ } \mu\text{L}$$

Étape 5 — Volumes finaux :

Tube	$V_B \text{ (}\mu\text{L)}$	$V_A \text{ (}\mu\text{L)}$
Tube 1 (zéro)	0	500
Tube 2	19	481
Tube 3	231	269
Tube 4	269	231
Tube 5	481	19

Les tubes 3 et 4 encadrent $V_{\text{eq}} = 250 \text{ } \mu\text{L}$ de près ; les tubes 2 et 5 couvrent les extrémités.
 $V_{A,j} + V_{B,j} = 500 \text{ } \mu\text{L}$ dans tous les tubes.

8 Formats de fichiers attendus

8.1 Fichiers spectres .txt

- En-tête contenant une ligne qui commence par `Pixel;`. Toutes les lignes avant cette ligne sont ignorées.
- **Séparateur de colonnes** : point-virgule (`;`).
- **Séparateur décimal** : virgule (`,`).

- Colonnes requises après lecture :
 - `Raman Shift` : nombres d'onde en cm^{-1} .
 - `Dark Subtracted #1` : intensité brute (après soustraction du fond obscur).
- Le pipeline produit automatiquement :
 - `Intensity_corrected = Dark Subtracted #1 - baseline(modpoly)`.
 - `file` : nom du fichier `.txt`.
 - `Spectrum name` : nom sans l'extension `.txt` (clé de jointure avec les métadonnées).

Validations appliquées automatiquement :

- Vérification de la plage physique : $-200 \leq \nu \leq 10\,000 \text{ cm}^{-1}$.
- Détection et moyennage des doublons de Raman Shift.
- Tri par Raman Shift croissant.
- Suppression des lignes avec des valeurs manquantes dans les colonnes essentielles.

8.2 Fichier de métadonnées

- **Excel** : `.xlsx` ou `.xls` (lu via `openpyxl`).
- **CSV** : `.csv`, séparateur auto-déTECTÉ parmi `,`, `;` et tabulation, encodage UTF-8 recommandé.
- **Colonne obligatoire** : `Spectrum name` (clé de jointure avec les spectres).
- Colonnes utiles : `Sample description`, `n(EGTA)` (`mol`), colonnes de concentration...

9 Détails techniques (modules)

9.1 `data_processing.py`

Ce module gère le chargement et l'assemblage des données.

- `load_spectrum_file(path, poly_order=5, apply_baseline=True)` :
 - Détecte et ignore l'en-tête jusqu'à la ligne `Pixel`;
 - Lit le fichier avec séparateur `;` et décimales `,`.
 - Convertit en numérique, supprime les NaN, trie sur Raman Shift.
 - Vérifie la plage physique (-200 – $10\,000 \text{ cm}^{-1}$) et signale les valeurs suspectes.

- Détecte et moyenne les doublons de Raman Shift.
- Applique la correction de baseline modpoly (si demandée).
- Retourne un DataFrame avec `Raman Shift`, `Dark Subtracted #1`, `Intensity_corrected`, `file`.
- `build_combined_dataframe_from_df(txt_files, metadata_df, ...)` :
 - Charge chaque fichier `.txt` via `load_spectrum_file`.
 - Concatène les spectres valides, ajoute `Spectrum name`.
 - Fusion gauche sur `Spectrum name` avec les métadonnées.
 - Retire les contrôles BRB si `exclude_brb=True`.
- `load_combined_df(parent, file_picker, metadata_creator)` : wrapper gérant toutes les erreurs via `QMessageBox` (vérifie que les métadonnées et les fichiers sont disponibles, appelle `build_merged_metadata` puis `build_combined_dataframe_from_ui`).

9.2 metadata_model.py

Couche données pure (**aucun import Qt**), testable sans interface graphique. Sépare la logique métier de l'interface utilisateur.

- `to_float(x)` : conversion robuste d'une valeur quelconque (str avec virgule, espace insécable, NaN, None...) en float ou None.
- `conc_to_M(val, unit)` : convertit une concentration en mol/L selon l'unité (M, mM, μ M, nM, ...).
- `normalize_tube_label(label)` : normalise des variantes d'étiquettes de tube (A5, tube05, 5, ...) vers la forme canonique `Tube 5`.
- `norm_text_key(s)` : clé de comparaison insensible à la casse et aux accents (é, è, ê, ô, à, â, î, û...).
- `is_control_label(label)` : retourne `True` si le label correspond à « Contrôle » ou « Control » (tube réplikat).
- `get_tube_columns(df)` : retourne les colonnes `Tube N` d'un DataFrame, triées par numéro *N*.
- `infer_n_tubes_for_mapping(df_comp)` : déduit le nombre de tubes à partir du tableau des volumes. Fallback : 10 tubes.
- `tube_merge_key_for_mapping(label, n_tubes, df_comp)` : retourne la clé de jointure entre la correspondance spectres $\leftrightarrow$ tubes et le tableau des volumes (`Contrôle` $\rightarrow$ `Tube N`).

- `compute_concentration_table(df_comp)` : calcule les concentrations finales dans chaque tube à partir des volumes et des concentrations stock.
- `build_merged_metadata(df_comp, df_map)` : fusionne la correspondance spectres ↔ tubes avec les concentrations calculées. Détecte automatiquement le titrant.
- `sers_gaussian_volumes(...)` : génère la série de volumes de titrant selon la méthode des quantiles gaussiens déformés (cf. section 7).

9.3 `metadata_creator.py`

Interface Qt pour la saisie des métadonnées. Délègue tous les calculs purs à `metadata_model` (via des méthodes d'une ligne du type `return mm.fonction(...)`). Contient :

- Tableau des volumes (réactifs × tubes) avec éditeur interactif (`TableEditorDialog`).
- Tableau de correspondance spectres ↔ tubes, avec synchronisation automatique lors de la modification du tableau des volumes.
- Dialogue de génération de volumes gaussiens (`GaussianVolumesDialog`).
- Sauvegarde et chargement des métadonnées au format `.xlsx`.
- Méthode `build_merged_metadata()` exposée publiquement pour les autres onglets.

9.4 `spectra_plot.py`

- Charge le fichier combiné depuis `metadata_creator`.
- Filtre sur les fichiers sélectionnés (colonne `file`).
- Génère une figure Plotly interactive : une courbe par spectre, légende = `Sample description` si disponible.
- Export PNG intégré dans l'interface Plotly.

9.5 `analysis_tab.py`

- Recharge le fichier combiné via `load_combined_df`.
- Propose des jeux de pics prédéfinis (532 nm, 785 nm) ou une saisie manuelle.
- Calcule l'intensité maximale dans la fenêtre $[\nu_0 \pm \Delta\nu]$ pour chaque spectre et chaque pic.
- Calcule tous les ratios I_i/I_j pour chaque paire de pics (i, j) .
- Fusionne avec les métadonnées pour afficher les résultats en contexte.
- Graphique interactif des ratios vs une variable de métadonnées.

- Export Excel avec deux feuilles : **intensities** et **ratios**.

9.6 peak_selector.py

- Onglet **Exploration** : normalisation des spectres (norme vectorielle), sélection des pics cibles, tolérance réglable.
- **PCA corrélée** : PCA sur la matrice $n \times p_{\text{pics}}$ des intensités aux pics.
- **PCA libre** : PCA sur la matrice normalisée complète ($n \times p$). Les données traitées (**X**, loadings, scores) sont stockées comme attributs d'instance pour permettre la reconstruction.
- Sous-onglets :
 - *Scores* : graphe interactif de scores PC_i vs PC_j , coloré par variable de métadonnées.
 - *Loadings* : graphe des coefficients du loading pour chaque composante, en fonction du Raman Shift.
 - *Reconstruction* : reconstruction d'un spectre sélectionnable à partir de N composantes, avec affichage simultané du spectre original.
- Scatter matrix (matrice de nuages de points entre pics).

10 Export et sauvegardes

- **Fichier combiné** : CSV (.csv) ou Excel (.xlsx) au choix dans la boîte de dialogue. Le dernier chemin est mémorisé.
- **Résultats d'analyse** : toujours Excel (.xlsx), deux feuilles :
 - **intensities** : intensité maximale par pic et par spectre.
 - **ratios** : tous les ratios en format long (spectre, pic_num, pic_den, ratio, métadonnées).

11 Bonnes pratiques

1. S'assurer que **Spectrum name** dans les métadonnées correspond exactement aux noms de fichiers .txt (sans extension).
2. Utiliser des noms d'échantillons explicites dans **Sample description** pour des légendes lisibles.
3. Travailler en encodage UTF-8 pour les fichiers CSV.
4. En PCA, commencer par examiner le graphe Scores coloré par la variable d'intérêt (concentration, tube...), puis les Loadings pour comprendre la signification

physique des axes.

5. Regarder plusieurs composantes (PC1, PC2, PC3) : l'effet chimique recherché n'est pas toujours sur PC1.
6. Utiliser la Reconstruction pour vérifier intuitivement ce que chaque composante a capturé.
7. Vérifier que la correction de baseline est satisfaisante dans l'onglet Spectres avant toute analyse quantitative.

12 Dépannage (FAQ)

L'assemblage échoue avec un fichier de métadonnées. Vérifiez que la colonne `Spectrum name` est présente et correspond exactement aux noms de fichiers `.txt` (sans extension `.txt`, casse exacte). Pour les CSV, vérifiez le séparateur (, , ; ou tabulation) et l'encodage (UTF-8 recommandé).

Mon fichier combiné n'a pas de colonne `Intensity_corrected`. Les fichiers `.txt` doivent contenir les colonnes `Raman Shift` et `Dark Subtracted #1` après la ligne `Pixel;`. Vérifiez le séparateur (;) et le séparateur décimal (,).

Le tracé n'affiche rien dans l'onglet Spectres. Vérifiez que :

1. l'assemblage a réussi et le fichier combiné a bien été produit,
2. les fichiers sélectionnés dans l'onglet *Fichiers* existent dans la colonne `file` du combiné,
3. les colonnes `Raman Shift` et `Intensity_corrected` sont présentes.

L'analyse des pics signale des colonnes manquantes. Le fichier combiné doit au minimum contenir `Raman Shift`, `Intensity_corrected` et `file`. Pour le graphique des ratios, la variable de métadonnées sélectionnée (ex. `n(EGTA)` (`mol`)) doit également être présente.

La PCA n'affiche rien ou plante. Il faut au moins 2 spectres et que le nombre de composantes demandé ne dépasse pas le nombre de spectres (ou le nombre de pics pour la PCA corrélée). Vérifiez que l'assemblage a réussi avant de lancer l'analyse.

Les spectres contrôle n'apparaissent pas dans la PCA. Le label `Contrôle` dans le tableau de correspondance doit être orthographié exactement ainsi (avec la majuscule initiale). Il est mappé automatiquement au dernier tube du tableau des volumes.

13 Crédits et licence

- **Développement** : Alexandre Souchaud, CitizenSers.
- **Correction de baseline** : bibliothèque `pybaselines` (<https://github.com/derb12/pybaselines>).
- **Interface graphique** : PySide6 / Qt.
- **Graphiques interactifs** : Plotly.
- **PCA** : scikit-learn (`sklearn.decomposition.PCA`).
- **Statistiques** : NumPy, pandas, SciPy.

Projet académique / interne — CitizenSers. Tous droits réservés.