

Onglet PCA

*Analyse en Composantes Principales
appliquée aux spectres Raman/SERS de titration*

Documentation technique et guide d'interprétation

Ce document explique en détail le fonctionnement de l'onglet PCA du logiciel de traitement de données spectroscopie Raman/SERS - CitizenSers.

Il couvre : les algorithmes utilisés, les options disponibles,
les graphiques produits et leur interprétation pratique.

Sommaire

0. Preamble : qu'est-ce que la PCA ?
1. Pourquoi utiliser la PCA sur des spectres Raman ?
2. Preparation des donnees : du fichier .txt a la matrice
3. Construction de la matrice spectrale (pivot)
4. Options de normalisation
5. L'algorithme PCA : fonctionnement mathematique
6. Les scores - nuage de points PC1 vs PC2
7. Les loadings - quelles longueurs d'onde comptent ?
8. La variance expliquee
9. La reconstruction de spectre
10. Guide pratique d'utilisation pas a pas
11. Interpretation dans le contexte SERS/titration
12. Limites et precautions
13. Onglet Selection pics : correlation, paires et PCA correlee

0. Preambule : qu'est-ce que la PCA ?

> 0.1 - Definition

La PCA (Principal Component Analysis), ou Analyse en Composantes Principales (ACP) en français, est une méthode statistique multivariée. Son objectif est de transformer un jeu de données contenant de nombreuses variables corrélées en un nombre réduit de nouvelles variables indépendantes, appelées composantes principales (PC), qui condensent l'essentiel de l'information.

Dans le contexte de la spectroscopie Raman, un spectre est un objet de haute dimension : chaque spectre est décrit par plusieurs centaines à plusieurs milliers de valeurs d'intensité (une par longueur d'onde). La PCA permet de réduire cet espace énorme à 2 ou 3 dimensions lisibles par l'œil humain, sans perdre les tendances essentielles.

(i) Exemple concret : 15 spectres x 800 longueurs d'onde = un espace de dimension 800. La PCA réduit cela à un nuage de 15 points dans un plan 2D (PC1, PC2), qui capture souvent 80 à 95% de toute la variabilité des spectres.

> 0.2 - A quoi ça sert ?

La PCA répond à plusieurs questions concrètes en spectroscopie de titration :

- Mes spectres montrent-ils une évolution avec la concentration de titrant ? -> Si oui, ils s'organisent en gradient dans le nuage de scores.
- Quelles longueurs d'onde varient le plus entre conditions ? -> Les loadings l'indiquent sans hypothèse préalable.
- Y a-t-il des spectres aberrants (hotspot anormal, fluorescence, contamination) ? -> Un point isolé dans le nuage de scores signale un spectre atypique.
- La variabilité entre spectres est-elle d'origine chimique ou instrumentale ? -> Si la variance est corrigée par la normalisation L2, c'était de l'intensité SERS ; si elle persiste, c'est une vraie variation chimique.
- Quels pics Raman dois-je analyser pour mon ratio d'intensité ? -> Les loadings de la composante corrélée à la titration donnent directement les candidats.

> 0.3 - Comment ça marche ? (principe mathématique simplifié)

La PCA cherche les 'directions' dans l'espace des données qui capturent le maximum de variance. Voici le principe en 5 étapes :

> Etape 1 - Construction de la matrice

On assemble tous les spectres dans une matrice X de taille ($n_{\text{spectres}} \times n_{\text{wavenumbers}}$). Chaque ligne est un spectre, chaque colonne est une longueur d'onde.

> Etape 2 - Centrage

On soustrait la moyenne de chaque colonne (wavenumber). Chaque colonne a maintenant une moyenne de zéro. Cela place l'origine au 'spectre moyen'.

> Etape 3 - Recherche de la première composante (PC1)

On cherche la direction (vecteur dans l'espace des longueurs d'onde) le long de laquelle les projections des spectres ont la variance maximale. Cette direction est PC1. Le vecteur qui la définit s'appelle le 'loading' de PC1.

> Etape 4 - Composantes suivantes (PC2, PC3, ...)

On cherche ensuite la direction orthogonale a PC1 qui maximise la variance restante -> PC2. Puis la direction orthogonale a PC1 et PC2 -> PC3. Et ainsi de suite. L'orthogonalite garantit que chaque composante apporte une information nouvelle, independante des precedentes.

> Etape 5 - Projection (calcul des scores)

Chaque spectre est projete sur les composantes retenues. Sa coordonnee sur PC1 s'appelle 'score PC1', sur PC2 'score PC2', etc. Ces scores sont les coordonnees du spectre dans le nouvel espace reduit.

Mathematiquement : $X_{centree} = U \times S \times V^T$ (SVD)

Scores = $U \times S$ (coordonnees des spectres, taille $n_{spectres} \times n_{comp}$)

Loadings = V (directions des composantes, taille $n_{comp} \times n_{wavenumbers}$)

Variance expliquee par $P_{ck} = S_k^2 / \text{somme}(S^2)$

*U, S, V : matrice
Cette formule*

> 0.4 - Comment s'en servir en pratique ?

L'utilisation de la PCA suit toujours le meme enchaînement logique :

- 1. Charger les spectres corriges et les metadonnees de l'experience (tubes, concentrations, volumes).
- 2. Choisir la normalisation adaptee : L2 pour SERS (supprime la variabilite d'intensite), Z-score pour equaliser tous les pics, ou aucune si les intensites sont homogenes.
- 3. Lancer la PCA et lire la variance expliquee : PC1 capte quelle fraction de la variabilite ?
- 4. Visualiser le nuage de scores (PC1 vs PC2) en colorant par la concentration de titrant. Un gradient de couleur = la PCA a trouve l'axe chimique.
- 5. Lire les loadings de la composante correele au titrant : les pics avec les plus grands |loadings| sont les candidats au ratio d'intensite.
- 6. Verifier les spectres atypiques avec la reconstruction : residu = ce que la PCA n'explique pas.
- 7. Passer a l'onglet 'Selection pics' pour un classement automatique des meilleures paires de pics.

(i) La PCA n'est pas une fin en soi : c'est un outil exploratoire. Elle oriente l'analyse vers les bons pics et signale les spectres problematiques. La conclusion quantitative (valeur de l'equivalence, courbe de titration) vient ensuite avec l'onglet 'Analyse'.

1. Pourquoi utiliser la PCA sur des spectres Raman ?

Un spectre Raman contient typiquement plusieurs centaines à plusieurs milliers de points (un nombre d'intensité par longueur d'onde mesurée). Dans une expérience de titration SERS, on acquiert un spectre par tube (condition de concentration différente), ce qui peut représenter 8 à 30 spectres selon le plan expérimental.

Analyser chaque pic à la main prend du temps et suppose que l'on sait à l'avance quels pics regarder. La PCA permet de :

- Résumer l'ensemble des spectres en quelques 'axes' (PC1, PC2, ...) qui capturent l'essentiel des variations sans hypothèse préalable.
- Visualiser d'un seul coup d'œil si les spectres forment des groupes, si des spectres aberrants existent (hot spots SERS très intenses), ou si une tendance claire existe en fonction de la concentration de titrant.
- Identifier les longueurs d'onde (Raman Shifts) qui changent le plus entre conditions via les loadings, sans avoir à les choisir a priori.
- Détecter des spectres parasites (fluorescence forte, bruit excessif) avant de les exclure de l'analyse des pics individuels.
- Valider que la variation observée est bien liée à la chimie (titration) et non à un artefact instrumental ou à la variabilité SERS.

(i) La PCA ne remplace pas l'analyse des pics - elle la prépare. Elle indique 'regardez ces régions spectrales' sans vous forcer à les choisir a priori. Le logiciel propose ensuite l'onglet 'Selection pics' pour exploiter cela.

2. Préparation des données : du fichier .txt à la matrice

> 2.1 - Lecture des fichiers spectres

Chaque fichier .txt contient un spectre brut : deux colonnes séparées par des tabulations ou espaces (Raman Shift en cm^{-1} et intensité brute 'Dark Subtracted #1'). L'application lit ces fichiers et applique un prétraitement en deux étapes :

- Correction de ligne de base (baseline) par polynôme d'ordre 5, méthode asymétrique. Cette correction retire la fluorescence de fond et la dérive lente du spectre. L'intensité corrigée est stockée dans la colonne 'Intensity_corrected'. C'est cette valeur (et non l'intensité brute) que la PCA utilise.
- Les spectres 'Tube BRB' (blanc de référence tampon) sont exclus par défaut, car ils ne contiennent pas l'information de titration.

> 2.2 - Fusion avec les métadonnées

Chaque spectre est associé à un tube (condition expérimentale) via le tableau de correspondance créé dans l'onglet Métadonnées. Ce tableau relie :

- 'Nom du spectre' (nom du fichier sans .txt) -> 'Tube' (ex: Tube 1, Tube 2, Contrôle)
- 'Tube' -> volumes des solutions A, B, C injectées dans la cuvette
- La quantité de titrant $n(\text{titrant})$ en mol est calculée : $n = C(\text{Solution B}) \times V_{\text{cuvette}}$ (en litres).

Le résultat est un DataFrame combiné contenant, pour chaque ligne spectre x wavenumber : l'intensité

corrige + toutes les metadonnees du tube correspondant.

(i) Si les metadonnees sont absentes ou mal renseignees, la PCA fonctionnera quand meme (elle ne necessite que les intensites), mais les couleurs de points et la correlation avec la concentration de titrant ne seront pas disponibles.

3. Construction de la matrice spectrale (pivot)

La PCA requiert une matrice rectangulaire unique. Le DataFrame combine (long format : une ligne par couple spectre x wavenumber) est transformé en format large (wide) par une opération de pivot :

`X = matrice (n_spectres x n_wavenumbers)`

`n_spectres`
`n_wavenumbers`

Construction :

- Chaque ligne = un spectre, identifié par son 'Spectrum name' ou 'file'.
- Chaque colonne = une valeur de Raman Shift (cm^{-1}).
- La valeur dans la cellule = intensité corrigée à ce shift pour ce spectre.
- Si plusieurs mesures existent pour le même couple (spectre, shift), on prend la moyenne (`aggfunc='mean'`).
- Les colonnes entièrement vides sont supprimées.
- Les cases manquantes (NaN) sont remplacées par la moyenne de la colonne correspondante (imputation par la moyenne des autres spectres au même wavenumber).

> Filtrage par plage Raman

Les spinboxes 'Raman min' et 'Raman max' de l'interface permettent de restreindre la plage de longueurs d'onde incluses dans la matrice. Ce filtrage a lieu AVANT le pivot. Effets :

- Exclure les régions non informatives (ex : bord de spectre avec fluorescence résiduelle ou bruit élevé) améliore la qualité des composantes principales.
- Réduire la plage réduit `n_wavenumbers`, accélère le calcul et rend les loadings plus lisibles.
- La plage par défaut est remplie automatiquement depuis les données réelles au moment du chargement.

(i) Conseil : commencer avec la plage complète. Regarder les loadings. Identifier les régions 'plates' (loading proche de 0 partout). Restreindre la plage à la zone active et relancer.

4. Options de normalisation

Avant de lancer la PCA, la matrice X peut être normalisée. Ce choix est crucial car il détermine ce que la PCA va 'voir' comme source de variation.

> Option 1 : Aucune normalisation (centrage seulement)

La matrice X est utilisée telle quelle. La PCA (implémentation scikit-learn) centrera automatiquement chaque colonne (wavenumber) en soustrayant sa moyenne. Conséquences :

- PC1 sera dominé par la variance absolue d'intensité.
- En SERS, si certains spectres sont globalement plus intenses (hotspot brillant vs. faible), PC1 reflète simplement cette intensité globale, sans lien avec la chimie de titration.
- À utiliser quand tous les spectres ont des intensités comparables (expérience bien contrôlée, peu de fluctuation SERS).

> Option 2 : Normalisation L2 (recommandee pour SERS)

$$x'_i = x_i / ||x_i||_2 \quad \text{pour chaque spectre } i$$

$||x_i||_2 = \text{rac}$
Après normal

Chaque spectre est ramene a une norme egale a 1. Les variations d'intensite globale (dues aux fluctuations SERS de hotspot a hotspot) sont supprimees. La PCA voit uniquement la forme du spectre, pas son intensite absolue.

- Recommandee en SERS ou l'intensite fluctue fortement entre hotspots.
- Les differences de ratio de pics (I_A/I_B) deviennent plus visibles.
- Si deux spectres ont exactement la meme forme mais des intensites tres differentes, ils seront superposes apres L2.

> Option 3 : Standardisation Z-score (par longueur d'onde)

$$x'_{ij} = (x_{ij} - \text{moyenne}_j) / \text{ecart_type}_j$$

Pour chaque
Resultat : cha

Toutes les longueurs d'onde contribuent egalement a la PCA, independamment de leur intensite absolue. Un pic a 1 000 coups et un pic a 10 coups auront le meme poids.

- Utile si l'information est dans de petits pics souvent eclipses par les grands.
- Attention : amplifie aussi le bruit dans les regions peu intenses. A utiliser avec prudence si le rapport signal/bruit est heterogene.

(i) Recommandation pour SERS/titration : commencer par L2. Si PC1 explique encore >70% de variance avec L2, c'est qu'une autre source domine ; essayer Z-score. Si les resultats sont incoherents avec Z-score, revenir a L2.

5. L'algorithme PCA : fonctionnement mathématique

La PCA cherche les directions dans l'espace des longueurs d'onde qui maximisent la variance des données projetées. L'implémentation utilisée est celle de scikit-learn (PCA), basée sur la décomposition en valeurs singulières (SVD).

> 5.1 - Centrage automatique

Quelle que soit la normalisation choisie, la PCA (scikit-learn) centre automatiquement la matrice en soustrayant la moyenne de chaque colonne (c'est-à-dire la moyenne de chaque wavenumber sur tous les spectres) :

```
X_centree = X - moyenne(X, axe=spectres)
```

```
pca.mean_ = vecteur de dimension n_wavenumbers contenant ces moyennes
```

> 5.2 - Décomposition SVD

```
X_centree = U x S x V^T
```

U : matrice (n ,
 S : vecteur de
 V : matrice (n ,
 -> stockée dans

> 5.3 - Calcul des scores

Les scores sont les coordonnées des spectres dans l'espace réduit :

```
scores = X_centree x V^T = U x S
```

$scores[i, k] =$
 Dimension : (n ,
 -> stockée dans

Deux spectres proches dans l'espace des scores (distance euclidienne faible) ont des profils Raman similaires (après normalisation).

> 5.4 - Calcul des loadings

```
loadings = V (lignes de pca.components_)
```

```
loadings[k, j] = contribution du wavenumber j à la composante k
```

Dimension : (n ,
 -> stockée dans

Les loadings décrivent 'quelle combinaison de longueurs d'onde' définit chaque composante principale. Un loading fortement positif à 1231 cm^{-1} sur PC1 signifie que PC1 augmente quand l'intensité à 1231 cm^{-1} est élevée.

> 5.5 - Variance expliquée

```
var_k = S_k^2 / somme_totale(S^2) (en fraction)
```

```
var_k (%) = var_k x 100
```

Stockée dans p

Exprimee en pourcentage, elle indique l'importance de chaque composante. PC1 explique toujours la fraction la plus grande, PC2 la seconde, etc. La somme des variances de toutes les composantes = 100%.

> 5.6 - Nombre de composantes

Le parametre 'Nombre de composantes' (default : 5) determine combien de PC sont calculees. Ce nombre est limite par :

```
n_comp <= min(n_spectres - 1, n_wavenumbers)
```

Exemple : 12

Retenir trop peu de composantes = perdre de l'information. Retenir trop = inclure du bruit. La regle pratique : s'arreter quand la variance cumulee depasse 85-90%.

6. Les scores - nuage de points PC1 vs PC2

Le graphique des scores est la visualisation centrale de la PCA. Il projette chaque spectre comme un point dans le plan forme par les deux premieres composantes principales.

> 6.1 - Lecture du nuage

- Deux spectres proches (petite distance) = profils Raman similaires.
- Deux spectres eloignes = profils Raman differents.
- Un groupe de points = classe de spectres avec un comportement commun.
- Un point isole = spectre atypique : hotspot tres brillant, bruit eleve, fluorescence non corrige, contamination.
- Les axes PC1 et PC2 sont orthogonaux par construction (independants mathematiquement).

> 6.2 - Coloration par variable

La combo 'Colorer par' permet de superposer une variable experimentale sur le nuage :

- Colorer par '[titrant] (M)' ou 'n(titrant) (mol)' : si les spectres s'organisent en gradient de couleur le long de PC1 (ou PC2), cela prouve que cette composante capture l'evolution chimique de la titration. C'est le resultat ideal.
- Colorer par 'Tube' : verifie si les replicats d'un meme tube sont proches.
- Colorer par 'Sample description' : repere les classes d'echantillons (ex : avant/apres ajout, different pH).

> 6.3 - Que faire si PC1 ne correleles pas avec la chimie ?

En SERS, il est frequent que PC1 capture 'l'intensite globale' plutot que la chimie. Plusieurs strategies :

- Appliquer la normalisation L2 et relancer la PCA. Cela divise chaque spectre par sa norme et supprime la variance d'intensite absolue.
- Regarder PC2 et PC3 plutot que PC1. En colorant par concentration, si PC2 montre un gradient clair -> PC2 porte la chimie.
- Utiliser l'onglet 'Selection pics' qui calcule explicitement la correlation de chaque composante avec n(titrant).

(i) Astuce : si les points forment une ligne diagonale de bas-gauche a haut-droit dans le plan PC1-PC2, c'est souvent le signe que PC1 = intensite globale et PC2 = forme du spectre. La normalisation L2 corrige generalement cela.

> 6.4 - Comprendre concretement PC1 et PC2

PC1 et PC2 ne sont pas des spectres reels. Ce sont des directions abstraites dans l'espace de variation des spectres. Voici une analogie :

Imaginez que vos spectres varient principalement selon deux effets independants : (A) l'intensite globale SERS change d'un hotspot a l'autre, et (B) le ratio de deux pics change avec la concentration de titrant. La PCA va automatiquement construire PC1 = direction de A (car c'est la plus grande source de variance) et PC2 = direction de B (orthogonale a A).

- La coordonnee d'un spectre sur PC1 (son 'score PC1') dit 'a quel point ce spectre est extremement intense (ou peu intense)'. Ce n'est pas une concentration.

- La coordonnee sur PC2 (son 'score PC2') dit 'a quel point ce spectre a subi l'effet chimique de la titration'
- si PC2 porte la chimie.
- Dans le nuage PC1 vs PC2, un point en haut a droite n'est pas 'meilleur' qu'un point en bas a gauche. Les axes n'ont pas de valeur absolue physique - c'est leur POSITION RELATIVE par rapport aux autres points qui compte.

Ce qui peut etre troublant : si PC1 ne porte pas la chimie de titration, les points ne montrent pas de gradient par concentration sur l'axe horizontal. Il faut alors regarder PC2 (axe vertical) ou meme PC3 (en changeant les axes affichees). La composante qui porte la chimie est celle dont les scores montrent un gradient de couleur quand on colore par $n(\text{titrant})$. L'onglet 'Selection pics' calcule automatiquement $|\rho(\text{PCk}, n(\text{titrant}))|$ pour toutes les composantes et identifie la bonne.

Exemple concret (3 spectres, 4 wavenumbers) :

Spectre 1 (tube sans titrant) : [100, 200, 150, 80]

Spectre 2 (tube avec titrant) : [110, 180, 170, 90]

Spectre 3 (tube titrant x2) : [105, 160, 200, 85]

Score PC1 spectre 1 = -0.8 (peu concerne par l'effet dominant)

Score PC1 spectre 2 = 0.1 (effet moyen)

Score PC1 spectre 3 = 0.7 (tres concerne par l'effet dominant)

Si PC1 correlele avec la concentration -> PC1 porte la chimie.

Les valeurs e

7. Les loadings - quelles longueurs d'onde comptent ?

Les loadings sont des 'spectres virtuels' qui decrivent la direction de chaque composante principale dans l'espace des longueurs d'onde.

> 7.1 - Lecture d'un loading

Pour la composante PCk, le loading est une courbe Loading(shift).

- Loading fortement positif au shift X : quand PCk est eleve, l'intensite a X est elevee. Le pic a X est caracteristique des spectres avec un score PCk fort.
- Loading fortement negatif au shift X : quand PCk est eleve, l'intensite a X est faible. Ce pic contribue 'en sens inverse' a PCk.
- Loading proche de 0 au shift X : ce shift ne contribue pas significativement a PCk.

> 7.2 - Signature d'une reaction chimique

Une signature typique de reaction chimique (changement de conformation, de liaison, de protonation) dans les loadings est un profil 'bipolaire' :

- Loading positif sur un pic (ex : 1231 cm^{-1}) + loading negatif sur un autre (ex : 1256 cm^{-1}) sur la meme composante.
- Cela signifie que, quand le spectre se deplace le long de PCk, le pic a 1231 cm^{-1} augmente PENDANT

que le pic a 1256 cm^{-1} diminue.

- Ce type d'echange est exactement ce que capture le ratio I_{1231}/I_{1256} dans l'onglet Analyse.

> 7.3 - Identifier les candidats pour le ratio

Pour trouver les meilleurs candidats a analyser par ratio de pics :

- Identifier la composante PCk la plus correlee avec n(titrant) (via coloration dans les scores ou l'onglet 'Selection pics').
- Sur les loadings de PCk, noter les 2-3 positions avec les plus grands |loading| positifs et les 2-3 positions avec les plus grands |loading| negatifs.
- Former des paires (pic positif, pic negatif) et les tester dans l'onglet Analyse.

> 7.4 - Affichage PC1 & PC2 simultane

L'option 'PC1 & PC2' trace les deux loadings sur le meme graphe. Cela permet d'identifier :

- Les pics presents dans les deux composantes (forte variance globale).
- Les pics presents dans l'une mais pas l'autre (specifiques a une source de variation).
- Les regions ou les deux loadings se croisent ou divergent sont particulierement interessantes.

> 7.5 - Pourquoi les 'regions influentes' ne correspondent pas a la meilleure paire ?

C'est une question fondamentale. Les loadings et la meilleure paire de l'onglet 'Selection pics' sont deux choses differentes, calculees par deux methodes distinctes.

Les loadings repondent a : 'Quelles longueurs d'onde varient le plus le long de PCk ?'

La meilleure paire repond a : 'Quel rapport I_A/I_B correlele le mieux avec n(titrant) ?'

Ces deux questions ne donnent pas forcement la meme reponse. Voici pourquoi :

- Un loading fort = ce wavenumber varie beaucoup dans la direction de PCk. Mais PCk maximise la VARIANCE totale, pas la correlation avec n(titrant). Un pic peut tres bien varier beaucoup (fort loading) sans etre correle au titrant (ex : un pic qui fluctue aleatoirement a cause du bruit SERS aura une forte variance sans etre informatif pour la chimie).
- La meilleure paire utilise le rapport I_A/I_B , pas les intensites individuelles. Deux pics qui varient INDEPENDAMMENT peuvent avoir des loadings moyens, mais leur RAPPORT peut exploser en correlation si l'un monte quand l'autre descend. Le ratio amplifie les effets differentiels que les loadings individuels cachent.
- La 'meilleure PC' (la plus correlee avec n(titrant)) n'est pas toujours PC1. Si vous regardez les loadings de PC1 alors que c'est PC3 qui porte la chimie, vous ne verrez pas les bons pics. Utilisez les loadings de la PC la plus correlee avec n(titrant) (identifiee dans l'onglet 'Selection pics').

(i) Regle pratique : pour trouver la meilleure paire a partir des loadings, prenez la composante la plus correlee avec n(titrant). Identifiez le pic avec le plus grand loading POSITIF (pic A) et le pic avec le plus grand loading NEGATIF (pic B). Testez le ratio I_A/I_B . C'est exactement ce que l'algorithme 'Selection pics' fait de facon automatique et exhaustive sur toutes les combinaisons de candidats.

Exemple : loading PC2 a 1231 cm^{-1} = +0.45 (positif, monte avec PC2)

loading PC2 a 1256 cm^{-1} = -0.38 (negatif, descend avec PC2)

Si PC2 correlele avec n(titrant) :

- > quand titrant augmente, I_1231 augmente ET I_1256 diminue
- > le ratio I_1231/I_1256 varie DOUBLEMENT avec le titrant
- > c'est ce ratio que l'algorithme trouvera comme meilleure paire

C'est l'opposi

8. La variance expliquée

Affichée sous la forme 'PC1: 45.2% | PC2: 18.7% | PC3: 11.1% | ...', la variance expliquée renseigne sur la distribution de l'information dans les données.

> 8.1 - Interpretation des valeurs

- PC1 = 70-90% : un seul facteur dominant. En SERS sans normalisation, c'est souvent l'intensité globale. Appliquer L2 avant de relancer.
- PC1 = 40-60% + PC2 = 20-30% : deux sources de variation importantes. L'une peut être chimique (titration), l'autre instrumentale (hotspot, bruit).
- PC1 = 20-30% + beaucoup de petites PCs : variance très distribuée. Données potentiellement bruyantes ou très homogènes.
- Variance cumulée PC1+PC2 > 80% : le plan PC1-PC2 est une bonne représentation. Ce que vous voyez dans le nuage de scores capture bien les données.

> 8.2 - Nombre de composantes à retenir

Il n'y a pas de règle universelle. En pratique pour la spectroscopie SERS de titration :

- Retenir les composantes dont la variance individuelle dépasse 5%.
- S'arrêter quand la variance cumulée dépasse 85-90%.
- Vérifier que les loadings des composantes retenues ont des pics nets et reconnaissables (et non un profil chaotique = bruit).
- Un loading ressemblant à du bruit blanc (aucun pic net) indique que cette composante ne capture que du bruit de mesure.

(i) Règle pratique : pour 10-20 spectres de titration SERS, 3 à 5 composantes suffisent généralement. Au-delà, on capture du bruit. L'important est d'avoir la composante qui corrèle avec n (titrant).

9. La reconstruction de spectre

La reconstruction permet de vérifier la fidélité du modèle PCA pour un spectre donné. Elle compare le spectre original (après normalisation) au spectre que la PCA reconstituerait à partir des n composantes retenues.

> 9.1 - Calcul de la reconstruction

Pour un spectre x_{orig} (dans l'espace normalisé) :

```
x_centre = x_orig - pca.mean_

scores_single = x_centre x pca.components_^T
                (projection du spectre sur les composantes)

x_reconstruit = scores_single x pca.components_ + pca.mean_
                (reconstruction dans l'espace original)
```

pca.compone
pca.mean_

> 9.2 - Interpretation

- Reconstruction parfaite (courbes superposees) : le modele PCA capture toute l'information de ce spectre. Le residu est nul.
- Reconstruction imparfaite : le residu = $x_{orig} - x_{reconstruit}$ represente ce que la PCA n'a pas capture avec n composantes.
- Residu avec des pics nets : information non capturee par les n premieres PCs. Peut indiquer une structure spectrale unique a ce spectre.
- Residu plat et bruite : la PCA capture l'essentiel, le residu est du bruit de mesure. C'est la situation ideale.

> 9.3 - Usage pratique

Cas d'usage typique : selectionner un spectre atypique dans le nuage des scores (point isole) et regarder sa reconstruction. Le residu peut reveler :

- Un artefact de fluorescence : pic large et lent -> baseline mal corrige pour ce spectre specifique.
- Un pic de contamination : pic fin et tres intense a un shift inhabituel (ex : vibration d'une molecule etrangere).
- Un vrai signal chimique unique : hotspot tres specifique qui a amplifie preferentiellement une conformation moleculaire particuliere.
- Dans les deux premiers cas, le spectre devrait etre exclu de l'analyse et reacquis si possible.

10. Guide pratique d'utilisation pas a pas

Etape 1 - Prerequis

S'assurer que les onglets 'Fichiers' et 'Metadonnees' sont complets : fichiers .txt selectionnes, tableaux de composition et de correspondance tubes<->spectres definis et sauvegardes.

Etape 2 - Charger les donnees

Cliquer sur 'Recharger le fichier combine depuis Metadonnees'. Le bouton passe au vert si le chargement reussit. Le nombre de spectres charges s'affiche dans le label de statut.

Etape 3 - Plage Raman

Choisir la plage de Raman Shift. Conseil : commencer avec la plage complete (valeur remplie automatiquement). On affinera apres avoir vu les loadings.

Etape 4 - Normalisation

Choisir 'Norme L2' en premier essai. C'est le choix recommande pour SERS. Si PC1 explique >80% de variance meme avec L2, essayer le Z-score.

Etape 5 - Nombre de composantes

Laisser 5 en premier essai. Ajuster apres lecture de la variance expliquee (objectif : couvrir 85-90% de variance).

Etape 6 - Lancer la PCA

Cliquer 'Lancer la PCA'. Un message confirme la fin du calcul. Le label 'Variance expliquee' se met a jour. Les boutons de graphiques sont maintenant actifs.

Etape 7 - Lire la variance

Combien de % pour PC1 ? Si PC1 > 70% avec L2, quelque chose domine. Regarder le loading PC1 : ressemble-t-il au spectre moyen ? Si oui, c'est l'intensite globale. Tenter Z-score.

Etape 8 - Scores PC1 vs PC2

Ouvrir la fenetre des scores. Colorer par '[titrant] (M)' ou Tube. Y a-t-il un gradient de couleur dans une direction du nuage ? Si oui, cette direction porte la chimie de titration.

Etape 9 - Loadings

Afficher les loadings. Identifier les pics Raman avec les plus grands |loading| sur la PC correlee au titrant. Ce sont les candidats a analyser dans l'onglet 'Analyse' par ratio I_A/I_B.

Etape 10 - Reconstruction

Selectionner un spectre atypique (point eloigne dans le nuage des scores). Verifier sa reconstruction. Si le residu montre des pics nets, investiguer si ce spectre doit etre exclu.

Etape 11 - Iterer

Affiner la plage Raman pour exclure les regions non informatives. Relancer la PCA. Repeter jusqu'a obtenir une image claire de la chimie.

Etape 12 - Passer a 'Selection pics'

Utiliser l'onglet 'Selection pics' pour obtenir automatiquement : le spectre de correlation de Spearman, le classement des paires de pics, et la correlation de chaque PC avec n(titrant).

11. Interpretation dans le contexte SERS/titration

> 11.1 - Pattern typique d'une titration reussie

Dans une experience de titration SERS bien conduite, on observe typiquement :

- Les points dans le nuage de scores s'organisent selon une trajectoire ordonnee par concentration croissante de titrant (arc, ligne ou courbe sigmoide le long de PC1 ou PC2).
- Apres normalisation L2, PC1 ou PC2 correlele fortement avec $n(\text{titrant})$. Les loadings de cette composante montrent des pics en opposition de phase.
- Le point d'equivalence ($r \sim 1$) correspond souvent a un 'coude' ou un point d'inflexion dans la trajectoire du nuage de scores.

> 11.2 - Impact des hotspots SERS

En SERS, l'intensite varie fortement selon l'etat d'agregation des nanoparticules. On reconnait leur impact :

- Sans normalisation : PC1 explique 80-95% de variance et ses loadings ressemblent au spectre moyen -> PC1 = intensite globale.
- Apres L2 : PC1 chute a 30-50% et de nouvelles composantes avec des loadings structures apparaissent -> la chimie emerge.
- Un ou deux points tres eloignes des autres dans le nuage = hotspot unique ou spectre contamine. Verifier avec la reconstruction et decider de l'exclure ou non.

> 11.3 - Equivalence chimique dans la PCA

L'equivalence peut parfois se visualiser directement dans le nuage des scores : les points $r < 1$ (avant equivalence) sont d'un cote de la trajectoire et les points $r > 1$ de l'autre cote. La frontiere correspond a l'equivalence. Cependant, la PCA ne donne pas de valeur precise de l'equivalence. Pour une valeur quantitative, utiliser l'onglet 'Analyse' avec le fit sigmoide.

> 11.4 - PCA multi-runs

Si plusieurs manipulations (runs) sont chargees simultanement dans le logiciel :

- Les spectres du meme run formeront souvent un cluster distinct dans le nuage -> variabilite run-to-run visible.
- Si les clusters de runs differents sont alignes le long du meme axe que la concentration, la PCA est robuste et reproductible entre runs.
- Si les clusters sont orthogonaux a la concentration, il y a une variation systematique entre runs (ex : derive instrumentale, conditions de mesure differentes) qui devra etre corrgee avant l'analyse quantitative.

12. Limites et precautions

- La PCA est lineaire. Elle ne capturera pas bien des transitions non-lineaires abruptes. Les scores formeront une courbe plutot qu'une ligne dans le plan PC1-PC2, ce qui n'est pas un probleme mais rend l'interpretation moins directe.
- La PCA est non supervisee : elle maximise la variance, pas l'information chimique. Une source de

variance non chimique (bruit, fluorescence residuelle) peut dominer et masquer le signal de titration.

- Le nombre de composantes retenues influence la reconstruction. Plus on en retient, plus la reconstruction est fidele, mais plus on inclut du bruit. Il n'y a pas de nombre optimal universel.
- Le choix de la normalisation change radicalement les resultats. Il est recommande d'essayer les trois options et de comparer les nuages de scores.
- La PCA ne fonctionne pas bien avec tres peu de spectres (< 5). Avec seulement 4 spectres, toute la variance est expliquee par 3 composantes sans portee statistique reelle.
- Les outliers (valeurs aberrantes) ont un fort impact sur la PCA. Un seul spectre de tres haute intensite peut 'tirer' PC1 vers lui et fausser l'interpretation. Identifier et traiter les outliers avant la PCA.
- La correction de baseline doit etre bonne avant la PCA. Une baseline mal corrigelee pour certains spectres peut introduire une source de variance artificielle qui domine les premieres composantes.
- Les loadings doivent etre interpretes dans l'espace normalise. Avec la normalisation L2, un loading positif ne signifie pas 'ce pic est intense' mais 'ce pic est intense relativement aux autres pics dans ce spectre'.

13. Onglet Selection pics : correlation, paires et PCA correlee

L'onglet 'Selection pics' est un workflow automatise qui identifie, sans hypothese prealable, quels pics Raman portent l'information de titration et quelle paire de pics I_A/I_B est la plus pertinente pour la detection de l'equivalence. Il repose sur la correlation de Spearman, une mesure statistique non parametrique expliquee en detail ci-dessous.

> 13.1 - La correlation de Spearman (rho) : definition et calcul

Le rho de Spearman (note rho ou rs) est un coefficient de correlation non parametrique qui mesure si deux variables ont une relation MONOTONE, c'est-a-dire si quand l'une augmente, l'autre augmente (ou diminue) de facon coherente, sans exiger une relation lineaire parfaite.

Distinction importante avec la correlation de Pearson :

- Pearson mesure les relations LINEAIRES uniquement (droite $y = ax + b$). Sensible aux valeurs aberrantes. Suppose une distribution normale.
- Spearman mesure les relations MONOTONES (croissant ou decroissant). Insensible aux valeurs aberrantes. Capture les courbes sigmoïdes, exponentielles, les seuils. Pas d'hypothese de distribution. Ideal pour des relations chimiques non lineaires comme une titration.

> 13.1.1 - Comment calculer rho de Spearman

Le calcul se fait en 3 etapes :

Etape 1 : Remplacer chaque valeur par son rang.

Variables d'origine :

$I_j = [800, 200, 1200, 500, 900]$ (intensite au wavenumber j)

$n = [0.0, 0.5, 1.0, 0.8, 1.5]$ (quantite de titrant en mol)

Rangs de I_j : [3, 1, 5, 2, 4] (200 -> rang 1, 500 -> rang 2, ...)

Rangs de n : [1, 2, 4, 3, 5] (0.0 -> rang 1, 0.5 -> rang 2, ...)

Les rangs sont

Etape 2 : Calculer les differences de rangs $d_i = \text{rang}(I_j)_i - \text{rang}(n)_i$.

$d = [3-1, 1-2, 5-4, 2-3, 4-5] = [2, -1, 1, -1, -1]$

$d^2 = [4, 1, 1, 1, 1] \rightarrow \text{somme}(d^2) = 8$

Etape 3 : Appliquer la formule.

$\rho = 1 - (6 \times \text{somme}(d_i^2)) / (n \times (n^2 - 1))$

$\rho = 1 - (6 \times 8) / (5 \times (25 - 1))$
 $= 1 - 48 / 120$
 $= 1 - 0.40$
 $= 0.60$

n = nombre de
les ex-aequo

Dans le logiciel, ce calcul est repete pour CHAQUE wavenumber j , en calculant $\rho(I_j, n(\text{titrant}))$ sur tous les spectres. Le resultat est un 'spectre de correlation' : une valeur ρ pour chaque longueur d'onde.

> 13.1.1.b - Pourquoi cette formule mesure-t-elle la correlation ?

La cle est dans les RANGS. Tout s'explique en regardant les deux cas extremes :

Cas 1 : correlation parfaite (l'intensite suit exactement $n(\text{titrant})$)

Tube	Rang_n	Rang_I	d = Rg_n - Rg_I	d^2
1	1	1	0	0
2	2	2	0	0
3	3	3	0	0
4	4	4	0	0
5	5	5	0	0

somme(d^2) = 0

$\rho = 1 - (6 \times 0) / (5 \times 24) = 1 - 0 = 1.0$ <- correlation parfaite

Les rangs son

Cas 2 : anti-correlation parfaite (l'intensite fait exactement l'inverse)

Tube	Rang_n	Rang_I	d = Rg_n - Rg_I	d^2
1	1	5	-4	16
2	2	4	-2	4
3	3	3	0	0
4	4	2	2	4
5	5	1	4	16

somme(d^2) = 40

$\rho = 1 - (6 \times 40) / (5 \times 24) = 1 - 240/120 = 1 - 2 = -1.0$ <- anti-correlation parfaite

Les rangs son

Cas 3 : aucune correlation (rangs melanges aleatoirement)

Tube	Rang_n	Rang_I	d	d^2
1	1	3	-2	4
2	2	1	1	1
3	3	5	-2	4
4	4	2	2	4
5	5	4	1	1

somme(d^2) = 14

$\rho = 1 - (6 \times 14) / (5 \times 24) = 1 - 84/120 = 1 - 0.70 = 0.30$

Les rangs n'o
rapproche de

(i) RESUME : ρ mesure a quel point les classements (rangs) de deux variables se ressemblent. Rangs identiques -> $\rho = +1$. Rangs inverses -> $\rho = -1$. Rangs sans lien -> $\rho = 0$. Pas besoin de relation lineaire : seul l'ORDRE compte.

> 13.1.2 - Interpretation des valeurs de ρ

Les valeurs de rho vont toujours de -1 a +1 :

rho = +1.0	Relation parfaitement croissante. Quand n augmente, I augmente exactement.
rho = +0.7 a +1.0	Forte correlation positive. Ce pic augmente de facon fiable avec le titrant.
rho = +0.4 a +0.7	Correlation moderee positive. Tendence visible mais avec dispersion.
 rho < 0.4	Correlation faible. Ce pic ne suit pas bien le titrant.
rho = -0.4 a -0.7	Correlation moderee negative. Ce pic diminue avec le titrant.
rho = -0.7 a -1.0	Forte correlation negative. Ce pic diminue de facon fiable.
rho = -1.0	Relation parfaitement decroissante.

> 13.1.3 - Signe de rho et couleur des barres (rouge / bleu)

Dans le graphique 'Paires candidates', les barres sont colorees selon le signe de rho calcule pour le rapport I_A/I_B :

- ROUGE : $\rho > 0$. Quand on ajoute du titrant, le rapport I_A/I_B AUGMENTE. Le pic A monte relativement au pic B (ou le pic B descend). Chimiquement : A est la forme produite par la reaction, B est la forme consommee.
- BLEU : $\rho < 0$. Quand on ajoute du titrant, le rapport I_A/I_B DIMINUE. Le pic A descend relativement au pic B. Chimiquement : A est la forme consommee, B est la forme produite.

IMPORTANT : le signe ne change pas la QUALITE analytique de la paire. Une paire bleue avec $|\rho| = 0.90$ est aussi bonne qu'une paire rouge avec $|\rho| = 0.90$. La courbe de titration sera juste decroissante plutot que croissante. Dans l'onglet Analyse, le fit sigmoïde fonctionne dans les deux cas.

Astuce : si vous preferez une paire rouge plutot que bleue, il suffit d'inverser le rapport (utiliser I_B/I_A au lieu de I_A/I_B). Cela change le signe de rho sans changer $|\rho|$.

> 13.1.4 - Application concrete : comment rho est calcule sur un spectre Raman

Voici pas-a-pas comment le logiciel calcule rho pour UN wavenumber particulier. Ce calcul est repete pour chaque wavenumber du spectre (typiquement 1000 a 3000 points).

(i) Contexte : vous avez mesure N tubes, chacun avec une concentration differente de titrant. Pour chaque tube, vous avez un spectre Raman complet. Le logiciel veut savoir : 'a 1364 cm⁻¹, l'intensite augmente-t-elle quand on ajoute du titrant ?'

Etape 0 : les donnees de depart (exemple avec 6 tubes)

Spectre	n(titrant) (mol)	I a 1364 cm ⁻¹	Rang n	Rang I	d = Rg_n - Rg_I	d ²
Tube 1	0.00e-9	120	1	4	1-4 = -3	9
Tube 2	0.50e-9	85	2	2	2-2 = 0	0
Tube 3	1.00e-9	60	3	1	3-1 = 2	4
Tube 4	2.00e-9	140	4	5	4-5 = -1	1
Tube 5	4.00e-9	190	5	6	5-6 = -1	1
Tube 6	8.00e-9	110	6	3	6-3 = 3	9

Note : les rangs sont attribues de 1 (valeur la plus petite) a N (valeur la plus grande), independamment pour n et pour I.

Etape 1 : calculer la somme des d².

$$\text{somme}(d^2) = 9 + 0 + 4 + 1 + 1 + 9 = 24$$

$$N = 6 \text{ (nombre de spectres)}$$

Etape 2 : appliquer la formule de Spearman.

$$\rho = 1 - (6 \times \text{somme}(d^2)) / (N \times (N^2 - 1))$$

$$= 1 - (6 \times 24) / (6 \times (36 - 1))$$

$$= 1 - 144 / 210$$

$$= 1 - 0.686$$

$$= 0.314$$

rho = 0.31 : c

Si l'on refait le meme calcul a un autre wavenumber, par exemple 1409 cm⁻¹, et que les intensites suivent parfaitement l'ordre croissant de n(titrant), on obtiendrait rho = 1.0 (correlation parfaite).

> 13.1.5 - Pourquoi la courbe brute (rho point-a-point) est-elle si bruitee ?

Le logiciel calcule rho pour CHAQUE colonne de pixels du spectre, soit un calcul independant par wavenumber. Cela pose un probleme pratique :

- Les spectres Raman sont continus : le wavenumber 1363 cm⁻¹ et 1365 cm⁻¹ portent une information quasiment identique. Leurs rho individuels devraient donc etre proches.
- Mais chaque mesure de rho est basee sur seulement N spectres (souvent 8 a 15). Avec si peu de points, la variabilite statistique est grande : un seul spectre 'anormal' peut faire passer rho de 0.9 a 0.4 pour un seul wavenumber.
- Resultat : la courbe rho brute 'tremble' vite d'un wavenumber au suivant, rendant difficile l'identification

des vrais pics (maxima stables) par rapport au bruit statistique.

(i) Solution : on calcule $|\rho|$ puis on lisse par une moyenne glissante (fenêtre de quelques cm^{-1}). Les vrais pics Raman (larges de 5 à 30 cm^{-1}) ressortent comme des bosses stables, tandis que les fluctuations aléatoires point-à-point sont moyennées. C'est la 'Courbe 2 : $|\rho|$ lisse' visible dans l'onglet 'Selection pics'.

> 13.2 - Le graphique 'Correlation spectrale' : detail de chaque element

Ce graphique est le coeur de l'analyse. Il montre, pour chaque longueur d'onde, a quel point l'intensite a cette position est correlee avec la quantite de titrant. Il contient 3 courbes superposees et des indicateurs visuels.

(i) *Intuition generale : imaginez que pour chaque colonne de pixels du spectre (chaque wavenumber), on pose la question 'est-ce que l'intensite ici monte ou descend de facon coherente quand j'ajoute du titrant ?'. Les trois courbes repondent a cette question avec des niveaux de detail croissants.*

Courbe 1 : rho de Spearman brut (bleu clair semi-transparent)

Pour chaque wavenumber j , valeur brute de $\rho(I_j, n(\text{titrant}))$ calculee sur tous les spectres. C'est la mesure directe, point par point. Le signe indique le sens de la correlation :

$\rho = +1$: l'intensite monte exactement quand $n(\text{titrant})$ augmente

$\rho = -1$: l'intensite descend exactement quand $n(\text{titrant})$ augmente

$\rho = 0$: pas de relation monotone entre ce wavenumber et le titrant

PROBLEME de cette courbe brute : elle est tres bruitee car calculee point par point. Un wavenumber a des voisins presque identiques (les spectres sont continus), donc ρ oscille rapidement et il est difficile de distinguer les vrais pics des artefacts. C'est pour cela qu'on lui prefere la courbe 2 (lissee) pour l'identification des candidats.

Courbe 2 : $|\rho|$ lissee (bleu fonce, trait epais) -- LA COURBE PRINCIPALE

On prend la valeur absolue du ρ brut -- on 'oublie' le signe pour s'interesser uniquement a l'INTENSITE de la correlation (montante ou descendante, peu importe) -- puis on lissee par une moyenne glissante (parametre 'Fenetre de lissage' en cm^{-1}). Ce lissage supprime le bruit point-a-point et fait ressortir les regions spectrales coherentes.

$|\rho|$ va de 0 a 1 : 0 = aucune correlation, 1 = correlation parfaite (dans un sens ou l'autre). C'est la COURBE PRINCIPALE pour reperer les regions qui varient avec la chimie. Les maxima locaux de cette courbe sont les CANDIDATS PICS : les positions Raman qui bougent de facon consistante avec le titrant.

Courbe 3 : Dynamique normalisee (rouge tiretee, axe droit)

IMPORTANT : ce n'est PAS une correlation. C'est une mesure de combien l'intensite VARIE en valeur absolue entre tous les spectres, independamment de toute relation avec le titrant.

Formule : $(\max(I_j) - \min(I_j)) / \text{moyenne}(|I_j|)$, normalise entre 0 et 1 sur toute la plage.

Pourquoi cette courbe ? Un wavenumber peut avoir un bon ρ mais une variation minuscule (quelques unites sur des milliers, soit du bruit numerique). En multipliant $|\rho| \times \text{dynamique}$, on s'assure de ne retenir que les pics qui sont a la fois CORRELES au titrant ET REELLEMENT VISIBLES dans le spectre. Un pic intense qui varie beaucoup a une forte dynamique. Une region plate (bruit, ligne de base) a une faible dynamique.

Score combine (non affiche directement)

Score combine = $|\rho|$ lissee $\times$ dynamique normalisee. C'est ce score qui determine quels wavenumbers deviennent candidats. Un bon candidat doit avoir A LA FOIS une forte correlation avec $n(\text{titrant})$ ET une

forte amplitude de variation. Ce double critere elimine :

- Les regions bruitees a correlation artificielle (forte rho mais amplitude nulle)
- Les pics intenses qui ne varient pas avec le titrant (forte dynamique mais rho = 0)

Lignes vertes verticales : les candidats retenus

Maxima locaux du score combine qui dépassent 5% du maximum global (seuil de bruit). Le nombre de candidats est controle par le parametre 'Nombre de candidats' (default : 15). Une separation minimale de 20 cm^{-1} est imposee entre candidats pour eviter de selectionner plusieurs fois le meme pic (flancs d'un meme pic Raman large).

Ligne horizontale grise : rho = 0

Reference visuelle. Les wavenumbers dont rho brut est au-dessus = correlation positive avec titrant. En dessous = correlation negative. Permet de voir rapidement quelles regions montent et lesquelles descendent avec le titrant.

> 13.3 - Comment lire le graphique 'Correlation spectrale' en pratique

Etapas de lecture recommandees :

1. Reperer les maxima de la courbe bleu fonce ($|\rho|$ lisse). Ces positions sont les wavenumbers les plus informatifs pour la titration.
2. Verifier que ces maxima coincident avec de vrais pics Raman visibles dans l'onglet Spectres. Un maximum en $|\rho|$ dans une region plate du spectre est suspect (artefact numerique).
3. Regarder le signe du rho brut (courbe bleue claire) aux positions candidates : positif = pic qui monte avec titrant, negatif = pic qui descend.
4. Identifier des paires naturelles : un maximum positif + un maximum negatif forment la meilleure paire candidate. Leur rapport exploite l'opposition de phase.
5. Les zones ou le rho lisse et la dynamique sont tous deux eleves (courbes bleue et rouge se rejoignent) sont les zones les plus prometteuses.

(i) Si aucun maximum clair n'emerger ($|\rho|$ lisse plat partout), cela signifie soit que les spectres ne changent pas avec le titrant, soit que la normalisation choisie masque le signal. Essayer une autre normalisation ou verifier les metadonnees de concentration.

> 13.4 - Vue d'ensemble : relation entre PCA (loadings) et Selection pics (rho)

Ces deux analyses mesurent des choses complementaires mais differentes. Voici le tableau comparatif :

Critere	Loadings PCA	rho de Spearman (Selection pics)
Ce qui est calcule	Direction de variance maximale	Correlation monotone avec n(titrant)
Methode	SVD (algebre lineaire)	Rang de Spearman (statistique)
Question posee	Quelles longueurs d'onde varient ensemble ?	Quelles longueurs d'onde covarient avec la chimie ?
Resultat pic fort	Ce wavenumber contribue a PCK	Ce wavenumber suit le titrant
Meilleure paire	Loading + fort + loading - fort sur PCK correlee	Ratio I_A/I_B avec $ \rho $ maximal
Insensible a	La correlation avec une variable specifique	Les variations non liees a n(titrant)

(i) Strategie optimale : utiliser les deux de facon complementaire. La PCA identifie la composante la plus correlee avec n(titrant) et ses loadings suggerent des regions candidates. L'onglet 'Selection pics' confirme et classe les paires par force de correlation brute. Les deux outils convergent en general vers les memes pics - si ce n'est pas le cas, investiguer

pourquoi.

> 13.5 - Comment sont calculees les meilleures paires de pics ?

Une fois le spectre de corrélation calculé, le logiciel identifie les meilleures paires de pics en deux étapes enchainées.

> 13.5.1 - Etape 1 : identifier les pics candidats (wavenumbers individuels)

Le logiciel calcule le score combiné pour chaque wavenumber j :

$$\text{Score}(j) = |\rho(I_j, n)|_{\text{lisée}} \times \text{dynamique normalisée}(j)$$

Ce score est suffisante).

Les MAXIMA LOCAUX de ce score deviennent les 'pics candidats'. Par exemple : 1234, 1364, 1409, 1500, 1538, 1580, 1631 cm^{-1} .

Un paramètre 'Nb de candidats' contrôle combien de maxima sont retenus. Trop peu $\rightarrow$ on rate de bonnes paires. Trop $\rightarrow$ on teste des combinaisons peu pertinentes.

> 13.5.2 - Etape 2 : tester toutes les paires de candidats

Pour CHAQUE combinaison (pic A, pic B) parmi les candidats, le logiciel :

- Calcule le rapport I_A / I_B pour chaque spectre (un seul nombre par tube)
- Calcule $\rho(I_A/I_B, n(\text{titrant}))$ sur tous les spectres
- Retient $|\rho|$ comme score de la paire

Toutes les paires sont ensuite triées par $|\rho|$ décroissant.

> 13.5.3 - Pourquoi un rapport I_A/I_B plutôt qu'un pic seul ?

Exemple concret avec 4 tubes :

Tube	n(titrant)	I(1364)	I(1538)	I1364 / I1538
Tube 1	0 mol	200	800	0.25
Tube 2	20e-9 mol	300	600	0.50
Tube 3	40e-9 mol	400	400	1.00
Tube 4	60e-9 mol	500	200	2.50

Dans cet exemple :

- $\rho(I_{1364}, n)$ est bon, mais peut être perturbé si le laser fluctue : si la puissance monte de 10%, I_{1364} monte aussi... sans lien avec la chimie.
- $\rho(I_{1364}/I_{1538}, n)$ est ENCORE MEILLEUR : si le laser monte de 10%, I_{1364} et I_{1538} montent tous les deux de 10%, et le ratio reste constant. Seule la variation CHIMIQUE (réaction) modifie le rapport. Le rapport divise le bruit laser commun.

(i) Résumé du pipeline complet :

Spectres bruts

- $\rightarrow \rho(I_j, n)$ pour chaque wavenumber j
- $\rightarrow$ Spectre de corrélation (courbe brute, section 13.2)
- $\rightarrow |\rho|_{\text{lisée}} \times \text{dynamique} = \text{Score combiné}$
- $\rightarrow$ Maxima du score = pics candidats
- $\rightarrow$ Pour chaque paire (A, B) de candidats : $\rho(I_A/I_B, n)$

- > Tri par $|\rho|$ décroissant
- > Tableau 'Paires candidates' (onglet Selection pics)

Ce document a été généré automatiquement par `generate_doc_pca.py` à partir du code source de l'onglet PCA (`pca.py`) de l'application CitizenSers - Spectroscopie Raman.